



빅분기 필기 요약정리

▼ 1과목

#빅데이터의 이해

1. 빅데이터 개요 및 활용

- 빅데이터 : TB 이상의 정형/비정형 데이터 → 데이터에서 가치 추출&결과분석 하는 기술
- 빅데이터 활용 3대 요소 : 인력, 자원(데이터), 기술

- 빅데이터의 3V

- Volume(규모)
- Variety(다양성)
- Velocity(속도)
- + Value(가치), Veracity(신뢰성)
- + Validity(정확성), Volatility(휘발성)

정형 데이터	반정형 데이터	비정형 데이터
스키마구조 O 고정필드 O	스키마구조 O 메타데이터 O 고정필드 X	스키마구조 X 메타데이터 X 고정필드 X
RDBMS (Oracle, MS-SQL) 스프레드시트	XML, JSON, HTML, RSS 웹/시스템 로그, 알람, 센서 데이터	텍스트, 이미지, 동영상, 오디오 SNS, 이진파일

- 빅데이터 유형 (구조적 관점)

- 데이터의 종류

분류	하위 유형	의미	대표 예시
질적자료 (범주형)	명목형 (Nominal)	단순 구분, 순서 없음	성별(남/여), 혈액형(A/B), 지역명
	순서형 (Ordinal)	순서는 있음, 간격은 일정하지 않음	만족도(상/중/하), 학점(A/B/C), 계급
수치자료 (양적자료)	구간형 (Interval)	수치 간 차이는 의미 있음, 기준점 0은 없음	온도(섭씨), 연도, 시간
	비율형 (Ratio)	수치 간 차이와 비율 모두 의미 있음, 절대적 0 있음	키, 몸무게, 나이, 거리, 소득
자료 구조	횡단자료 (Cross-sectional)	한 시점에 여러 대상을 조사한 자료	2023년 전국 고등학생 키 조사
	종단자료 (Longitudinal)	한 대상을 여러 시점에 걸쳐 조사한 자료	2019~2023년 동안 한 학생의 키 변화


- DIKW 피라미드

Data 데이터	Information 정보	Knowledge 지식	Wisdom 지혜
객관적 사실	데이터간 연관관계&의미도출	정보를 구조화&일반화	깊은이해 → 창의적 아이디어
제품X가 사이트A에서 10,000원	제품X는 사이트A보다 사이트B에서 더 비싸게 판매함	사이트A에서 더 싸므로 제품X를 구매할 계획임	사이트B의 타제품들도 사이트A보다 더 비쌀 것으로 예측됨

- **암묵지**(나만 아는 지식) - **형식지**(문서, 메뉴얼 등으로 형상화)

→

공표연내



공통화 - 대화, 상호작용 (암묵지의 지식을 타인에게 알려줌)

표준화 - 문서화, 매체화

연결화 - 형식지 상호 결합 (교재, 메뉴얼에 새로운 지식 추가)

내연화 - 행동, 실천교육 (만들어진 교재, 메유럴로 타인의 암묵지 습득)

- 데이터베이스의 **특징** → **공통저변**

- 공용 데이터 : 여러 사용자가 공동 이용
- 통합된 데이터 : 중복 x
- 저장된 데이터
- 변화하는 데이터 : 새로운 데이터 추가, 수정에도 현재 데이터 유지 (무결성)

- 빅데이터가 만들어내는 변화 → **전후양상**

- 표본 → 전수조사
- 사전처리 → 사후처리
- 질 → 양
- 인과관계 → 상관관계

- 데이터 사이언스의 핵심 구성요소 → **AIB**

→

Analytics(이론적 지식) / **I**T(프로그래밍적 지식) / **B**usiness 분석(비즈니스적 능력)

- 데이터 사이언티스트의 필요역량

1. **하드 스킬** - 이론적 지식, 기술 숙련도 ...
2. **소프트 스킬** - 통찰력, 협력, 전달력 ...

- **하둡** : 여러 컴퓨터를 하나로 묶어 대용량 데이터를 처리하는 오픈 소스 솔루션

- 데이터 단위

KB < MB < GB < TB < PB < EB < ZB < YB

ex) 1 MB = 2¹⁰ KB

- 빅데이터 조직 및 인력방안 → **집기분**

1. **집중 구조** : 별도 전담부서 (우선순위 지정가능)
2. **기능 구조** : 각 현업 부서들에서 직접 분석 (따로 분석 조직이 없음)
3. **분산 구조** : 분석 조직의 인력을 각 부서로 배치

수직 업무활동	수평 업무활동	집중 구조	기능 구조	분산 구조
우선순위 결정	프로세스별로 업무 배분	별도 전담부서 우선순위 지정가능	해당 부서에서 분석 전사적 분석 어려움	각 부서로 배치 베스트 프랙티스 공유

2. 빅데이터 기술 및 제도

- 빅데이터 플랫폼의 계층 구조
 - **인프라(하위) < 플랫폼 < 소프트웨어 (상위)**
 - 인프라
- 딥러닝 < 머신러닝 < 인공지능
 - 약인공지능 : 주어진 조건에서만 동작
 - 강인공지능 : 인간과 동일한 사고가 가능
- 머신러닝의 종류
 - 지도학습 : 정답을 알려줌
 - 비지도학습 : 정답을 알려주지 않음
 - 강화학습 : 보상을 받기 위해 학습
- **전이학습** : 사전에 훈련된 모델을 재사용하는 학습 방식
 - fine-tuning : 이미 학습된 모델을 특정 타겟에 맞게 재조정
- **데이터 3법** : 개인정보보호법 / 정보통신망 ~ / 신용정보 ~
 - 주요 특징
 1. 가명정보의 가명 도입 ~ 가명처리 시 동의 없이 활용 가능
 2. 개인정보보호 거버넌스 체계 효율화
 3. 개인정보처리자 책임 강화 → 사용자의 책임
 4. 개인정보 판단기준 명확화
- 개인정보 비식별 조치 가이드라인 : 사전 검토 → 비식별조치 → 적정성 평가 → 사후 관리

#데이터분석 계획

1. 분석방안수립

- ★ 분석 대상과 방법

대상 방법	Known	UnKnown
Known	최적화 (Optimization)	통찰 (Insight)
Un-Known	솔루션 (Solution)	발견 (Discovery)

- 분석 기획 방안
 - 과제 중심적 접근 : 빠르게 해결
 - 장기적 마스터 플랜 : 지속적 분석 원인 해결

- 하향식 접근 방법**

- 문제가 먼저 주어지고 해결방법을 찾기 위해 진행

문제 탐색 → 문제 정의 → 해결방안 → 타당성 검토

- 문제 탐색 : 비즈니스 모델 캔버스 단순화 (5가지 단순화 - 업무/제품/고객/규제와감사/지원 인프라) ⇒ '지원인프라 업무 중 고객이 제품을 규제와 감사 했다'

- 상향식 접근 방법**

- 문제 정의 자체가 어려울 때

- 분석 방법론의 구성요소 : 전차, 방법, 도구와 기법, 템플릿과 산출물

- 분석 과제에서 고려해야 할 5가지 요소
 - 데이터 크기, 속도, 데이터 복잡도, 분석 복잡도, 정확도/정밀도
 - *정확도와 정밀도는 Trade-off 관계

- ★ ROI 관점 (Return On Investment) → 분석 과제 우선순위 선정

⇒ 투자대비 수익률을 관점으로 우선순위 선정

- 시급성 : 비즈니스 관점(Value)
 - 난이도 : 투자비용 요소 관점(3V - 다양성, 속도, 규모)

(어려움)	1	2
난이도		
(쉬움)	3	4
	(현재)	시급성 (미래)

- 시급성 중요 : 3사분면 → 4사분면 → 2사분면
 - 난이도 중요 : 3사분면 → 1사분면 → 2사분면

- 분석 방법론 모델

- 폭포수 모델 : Top-Down
- 나선형 모델 : 점진적으로 완성, 위험요소 제거에 초점

3. 프로토타입 모델 : 프로토타입을 우선 개발한 후 보완
4. 애자일 : 일정 주기를 가지고 프로토타입 끊임없이 수정 → 고객의 니즈 반영

- **KDD** 분석 방법론

- 데이터 **선택** (Selection) → 전처리 → 변환 → 마이닝 → 결과 평가

- **Crisp-DM** 분석 방법론 - 데이터를 이해한 후 준비

- 업무 이해 → **데이터 이해** → **데이터 준비** → **모델링** → **평가** → 전개

*모델링 단계에선 '모델 평가', 평가 단계에선 '모델 적용성 평가' 수행

→ Crisp-DM 분석 방법론의 단계 중 평가 단계에서 모델 평가를 수행한다 (X)

- **SEMMA** 분석 방법론 - 주 통계 중심

- 샘플링 → 탐색 → 수정 → 모델링 → 검증

- ★★★★★ **빅데이터 분석 방법론 (순서)**

- **PPADD**



- **분석기획 → 기획단계이므로 세부적인 항목 함께 나오면 그것이 오답**

1. 비즈니스 이해 및 범위 설정 : **구조화된 작업 기술서(SOW)** 작성
2. 프로젝트 정의 및 계획 수립 : 프로젝트 계획서, 목적, 기대효과, **작업분할구조도(WBS)** 작성
3. 프로젝트 위험계획 수립 : **회피**(기간 연장, 범위 축소..), **전이**(보험, 사후 보증), **완화**(절감 노력), **수용**(긴급 대책, 조치x, 백업 플랜)

- 데이터 분석 단계

: 분석용 데이터 준비 → 텍스트 분석 → 탐색적 분석(EDA) → 모델링(데이터 분석) → 모델 평가 및 검증


- **분석 거버넌스** 체계 구성요소

- 조직, 프로세스, 시스템, 데이터, 분석관련 교육 및 마인드 육성체계

- 데이터 분석 수준 진단

1. 분석 준비도 : 분석업무파악, 분석 인력 및 조직, 기법, 데이터, 문화, 인프라.. 등
2. 분석 성숙도 : CMMI 모델 기반, 비즈니스 / 조직, 역량 / IT 부문 관점으로 구분
→ 도입, 활용, 확산, 최적화 시기별로 각 관점에서의 내용 구분

- 데이터 분석 성숙도 모델 → 기업의 도입 적정성 여부 평가 ⇒ **도준정확**
→ 성숙도 = 얼마나 분석이 조직에 **정착**되었는가 | 준비도 = 분석할 **역량과 기반**이 갖춰졌는가



준비형 - 환경·인프라 정비 중

도입형 - 분석을 이제 막 시작

정착형 - 분석 업무가 정례화됨

확산형 - 전사 차원으로 확대 적용

- **데이터 거버넌스**
 - 전사 차원에서 데이터에 대해 표준화된 관리 체계 수립
 - 구성요소 : 원칙, 조직, 프로세스 (**원조프**)

#데이터 수집 및 저장 계획

1. 데이터 수집 및 전환

- **데이터 수집 기술**
 1. **ETL** : 추출 - 변환 - 적재 (**전통적 수집**) ex) DB → DW로 데이터 옮기기
 2. **FTP** : TCP/IP 네트워크에서 컴퓨터 간 파일 교환
 3. **Open API** : 공개된 API 통해 데이터 요청, 수신
 4. **스콥 SQOOP** : (RDBMS - 하둡) 간 대용량 데이터 전송
 5. **웹 크롤링 (Crawling)** - 웹사이트에서 데이터 자동 수집
- 반정형 데이터는 '메타데이터'(설명해주는 데이터)를 포함
- **개인정보 비식별화**
 - 데이터 마스킹
 - 가명처리
 - 총계처리 (합, 평균.. 등)
 - 범주화 (34세 → 30~40세)
- **프라이버시 보호 모델**
 1. **k-익명성** : 일정 수준 이상으로 비식별 되도록 함
 2. **l-다양성** : 다양성 높임 (민감한 정보)
 3. **t-근접성** : 분포를 낮춤

- 데이터 품질 기준 : 정확성, 일관성, 유용성, 접근성, 적시성, 보안성
 - 완전성 : 데이터가 결측치 없이 값을 가지고 있는지
 - 정확성 : 오류가 입력되지 않게 하고, 유효한 내용인지

2. 데이터 적재 및 저장

- 분산 파일 시스템

1. HDFS(하둡 분산파일 시스템) : **2개의 네임노드 (master)** + 데이터 노드
 - 분산 처리 - 시스템의 과부하 및 병목 현상 해소
 - 복제- 하나의 파일을 기본적으로 3개의 서버에 복제

1. 맵리듀스 (MapReduce) - '분산 병렬 처리 모델' **Map - Shuffle - reduce**

⇒ 대용량 데이터를 분산 시스템에서 빠르게 처리하기 위한 병렬 처리 모델

- **Input → Splitting → Mapping → Shuffling → Reducing**
- 입력 데이터를 쪼개서 맵핑하고 섞은 후 분류함
- 중복 제거, 합계 계산에 유용
- 하둡에서 채택한 프로그래밍 모델

3. GFS (Google File System) - '분산 파일 저장 시스템' 고장에 강함 + 읽기 위주

⇒ 구글이 빅데이터 저장/처리를 위해 직접 만든 분산 파일 시스템

- 파일을 여러 조각(Chunk)으로 나눠 저장
- **복제(Replication)로 장애 대비** *하나의 Chunk가 여러 서버에 복제 기본 3개
- 분산 파일 시스템으로 하둡에 영향을 줌
- 쓰기보다 읽기 위주 - 분석용 데이터 특성에 맞춤

- 데이터베이스

- 관계형 데이터베이스 : 정형 데이터 처리

*병렬DBMS : 대규모 처리를 위해 일정 단위로 나눠 병렬처리하는 시스템, 빠른 처리가 가능하며 시스템 용량 확장이 용이함 (중복 저장과는 관련 x)

- NoSQL : 비정형 데이터 처리

- DW, DM, Data Lake

1. 데이터 웨어하우스(DW)

⇒ 정형 데이터 저장 + 주제지향성, 데이터 통합(일관된 형식), 시계열성, 비휘발성

2. 데이터 마트(DM) : 데이터 웨어하우스의 한 분야, 특정 목적을 위해 사용

⇒ 분석이 편하도록 **미리 요약한 정보**를 모아둔 곳 (요약변수가 기본 변수)

3. 데이터 레이크 : 다양한 유형의 대량 데이터 저장, 원시(RAW) 및 비정형 데이터 저장, 하둡과 연계

SCM	ERP	CRM	DW	DM
물류흐름을 하나의 가치사슬 관점에서 파악	회사의 모든정보 + 공급 사슬관리 + 고객주문정보	고객을 만들고 장기간 유지하고자 함	데이터를 공통형식으로 변환&관리하는 저장소	DW에서 데이터를 꺼내 사용자에게 제공함
외부&제휴업체와 통합된 정보시스템 연계	통합적 관리 시스템	고객정보를 분석&저장	시간흐름에 따라 값 변화	특정업무 분야에 초점 작은 규모의 DW

▼ 2과목

#데이터 전처리

2. 분석 변수 처리

• 변수 선택 방법

- 전진선택법 : 상관계수의 절댓값이 큰 것(관련성 높음)부터 하나씩 추가
- 후진제거법 : 모두 있는 상태에서 상관계수의 절댓값이 작은 것 부터 하나씩 제거
- 단계별 선택법 : 전진 + 후진 → 보완

• 차원축소

*차원의 저주 : 데이터 학습 시 차원이 높아질수록 알고리즘 성능이 저하됨

- **주성분 분석 (PCA)** : 상관성 높은 변수의 선형 결합으로 차원 축소 & 새로운 변수 생성 (정방 행렬)
고차원 데이터를 저차원으로 줄이면서도, **데이터의 정보(분산)를 최대한 보존**하는 방법
→ 데이터 속성들 간의 중복(상관관계)을 제거해서,
→ 새로운 축(주성분)을 만들고 이 축에 **데이터를 투영**하는 방식
→ 변수간 상관관계가 있을 시 유용함 / 정규분포를 반드시 가정 X *기출
→ **직교변환(orthogonal transformation)** 사용
- 요인분석 : 요인들을 회전시켜 데이터 내부 잠재 요인을 도출하고 구조를 해석하는 기법
→ 독립/종속변수 구분 X / 기술 통계 기반 (공분산, 상관계수)
→ 변수들이 같은 요인끼리 묶이고, 각 **요인끼리는 서로 독립적** (직교)
 - 직각회전방식 - 요인들 사이 상관관계를 0으로 만들어 서로 독립적인 것으로 가정 (Varimax)
 - 사각회전방식 - 요인들 사이 상관관계를 0이 아닌 값으로 유지 (Promax, Oblimin)
- **다차원 척도법** : 개체 사이의 군집을 시각적으로 표현하는 방법
- 특이값 분해 (SVD) : MxN 크기의 비정방 행렬 분해
- 선형판별분석 & 독립성분분석

• 요약변수 & 파생변수

- 요약변수 : 수집된 정보를 종합하여 요약해 만든 변수 ex) 월 평균 기온
→ 주로 **집계(aggregate)** 형태 / 전체 흐름이나 특성을 간단히 보여줄 수 있음
→ 다양한 분석에 공통으로 사용 가능 (**재사용성 ↑**)
→ 데이터 마트에서 가장 기본적인 변수
- 파생변수 : 기존 변수를 변형하거나 결합해서 새로운 변수를 생성한 것
ex) 성별 + 연령 = '**중년 남성**'

- 논리적 타당성이 중요 (왜 만들었는지 설명 가능 해야함)
- 분석 목표에 따라 달라짐 (유연성 ↑)
- 머신머닝에서도 모델 성능 향상을 위해 사용

• 수치형 변수 변환

1. Z-score 정규화 : 평균 0, 표준편차 1로 변환

$$\frac{(\text{현재 값} - \text{평균})}{\text{표준편차}}$$

2. 최소-최대 정규화

$$\frac{(\text{현재값} - \text{최소값})}{(\text{최대값} - \text{최소값})}$$

3. 로그 변환 - 한쪽으로 치우친 그래프

• 범주형 변수 변환

1. 레이블 인코딩 : 데이터를 단순 정수로 변환 (0, 1, 2...)
*컴퓨터가 정수를 순서가 아닌 크기로 인식할 수 있음
2. 원-핫 인코딩 : 고유값 해당 칼럼만 1로 표시, 나머지는 0으로 표시 ex) [0, 0, 1]...
3. 타깃 인코딩 : 타깃 변수를 평균값으로 변환

• 불균형 데이터 처리

1. 가중치 균형 적용 : 불균형 데이터에 가중치를 줌
+) 비용민감학습 : 소수 클래스에 더 많은 가중치를 줌으로써 예측 정확도 향상 (모든 클래스의 중요도가 동일하지 않은 경우에 사용)
2. 언더샘플링 : 다수 데이터를 일부만 선택
3. 오버샘플링 : 소수 데이터를 복사해서 수를 늘림
*SMOTE : 가상 직선을 활용해 소수 클래스 데이터를 합성하는 오버샘플링 기법

#데이터 탐색

1. 데이터 탐색 기초

→ 데이터 분석 전, 데이터의 구조와 특징을 파악하는 과정

• EDA (탐색적 자료 분석)

특징	설명
목적	데이터 속에 숨겨진 의미나 패턴을 미리 확인하고 직관적으로 이해 하는 것
방법	통계 요약 + 시각화 사용 (ex: 평균, 분산, 히스토그램, 박스플롯 등)
결과	이후 분석(모델링)에 대한 방향 설정이 쉬워짐
실전 예	이상치 확인, 변수 간 관계 파악, 결측치 확인 등

• 4가지 주제 ⇒ **저잔재현**

- 저항성(이상치 영향 적게 받음), 잔차 계산, 자료변수의 재표현, 그래프를 통한 현시성

• 상관분석

- 피어슨 상관분석 양적 척도 (연속형 변수, 선형관계)
- 스피어만 상관분석 : 서열 척도 (비선형적 관계 나타냄)

피어슨 vs 스피어만 상관관계수 비교표

구분	피어슨 상관관계수 (Pearson)	스피어만 상관관계수 (Spearman)
 측정 대상	연속형 수치 데이터	서열형(순서형) 또는 연속형 데이터
 관계 유형	선형(직선) 관계만 측정	단조(monotonic) 관계 측정 → 선형, 비선형 모두 가능
 계산 방식	원래 데이터값을 그대로 사용해서 계산	데이터를 **순위(rank)**로 바꿔서 계산
 해석 범위	-1 ~ +1	-1 ~ +1
 0의 의미	선형 관계 없음	단조 관계 없음
 이상치 민감도	이상치에 매우 민감	이상치에 덜 민감
 표본크기 작을 때	신뢰도 떨어짐	상대적으로 안정적
 사용 예시	키와 몸무게처럼 정확한 수치 간 관계	만족도 점수(1~5)처럼 순위 중심 자료
 주로 쓰는 상황	정량적 분석, 회귀 전 상관 확인	순위자료, 데이터 왜곡 심할 때

- 첨도와 왜도
 1. **첨도** : 자료 분포가 얼마나 뾰족한지
 - 0 = 정규분포, 값이 클수록 뾰족함 (3을 기준으로 정규분포 형태를 판단하기도 함)
 2. **왜도** : 자료 분포의 비대칭 정도
 - 0보다 크면 오른쪽으로 꼬리 긴 형태 (최빈값 < 중앙값 < 평균값)
 - 0보다 작으면 왼쪽으로 꼬리 긴 형태 (최빈값 > 중앙값 > 평균값)

2. 고급 데이터 탐색

- 공간 데이터
 - 비 공간 타입 - 위치 정보가 아예 없는 데이터 ex) 전화번호
 - 레스터 공간 타입 - **픽셀**로 나눔, 객체 관계 표현 약함
 - 벡터 공간 타입 - 객체 그 자체, 관계 표현 X
 - 위상적 공간 타입 - 관계 중심으로 공간 표현
- 시공간 데이터 (공간 정보 + 시간 흐름)

#활용 : 시공간 패턴을 통한 예측, 지도를 통한 위치정보, 지리공간의 격자 차트 결합
- 다변량 데이터 탐색방법

*다변량 데이터 = 높은 차원의 데이터 ⇒ 차원을 축소해서 분석해야 함

 1. 주성분 분석(PCA)
 2. 다차원척도법(MDS) : 데이터간 거리를 보존하여 차원 축소
 3. 로컬선형임베딩(LLE)

#통계기법 이해

1. 기술통계

- 표본 추출 방법
 1. 랜덤 추출법 : 완전 무작위
 2. 계통 추출법 : 순서를 두고 일정 간격으로 추출
 3. 집락 추출법 : 여러 군집으로 나눈 뒤 군집을 선택하여 랜덤 추출
 - 군집 내 이질적, 군집 간 동질적
 4. 층화 추출법 : 유사한 요소끼리 층을 묶어서 층별 추출
 - 군집 내 동질적, 군집 간 이질적
 5. 복원 / 비복원 추출 : 복원 - 뽑은 거 다시 넣음, 비복원 - 안넣음
- 표본 추출 오차 - 전수조사가 힘드므로 표본을 추출하여 조사할 때, **모집단과 다른 차이**를 의미

→ 표본의 크기보다는 대표성이 더 중요함

 - 과잉 대표 : 어떤 애가 너무 많이 뽑힘 ex) 남자 50% 여자 50% 필요한 상황 여자 90%
 - 최소 대표 : 뽑아야 할 애가 너무 적게 뽑힘/다른애가 뽑힘 ex) 모집단-고등학생 50% 표본-10%
- 확률분포** : 확률변수가 어떤 값을 가질 확률을 알려주는 수식이나 그래프
 1. **이산 확률분포** - 값을 셀 수 있는 분포 (확률질량함수)

→ 예) 주사위 눈(1, 2, 3, 4, 5, 6), 동전 앞/뒤 등

◆ 대표 이산 분포 & 시험 포인트

분포 이름	설명	예시	시험 포인트
이산균등분포	모든 값이 나올 확률이 똑같음	주사위, 복권 번호	확률이 전부 같음 (1/n)
베르누이분포	한 번 시행에 결과가 두 개뿐	동전 앞/뒤 (1=성공, 0=실패)	성공 확률 = p
이항분포	베르누이 시행을 n번 반복	동전 10번 던져 앞면 몇 번?	공식: $P(X=k) = nCk p^k (1-p)^{n-k}$
기하분포	처음 성공할 때까지 걸리는 횟수	몇 번째에 첫 정답 맞힘?	“처음 성공” 기억!
다항분포	결과가 여러 개일 때 확률	주사위 60번 던졌을 때 각 눈의 횟수	베르누이의 확장
포아송분포	단위 시간/공간에서 발생하는 사건 횟수	1시간 동안 들어오는 전화 수	“희귀 사건”, λ(람다) 사용

⇒ 배포항항하이

2. **연속 확률분포** - 값을 셀 수 없고 연속적인 확률변수 - **확률밀도함수(PDF)** 이용

→ 예) 키, 몸무게, 온도, 시간

→ 한 점의 확률은 0이고, 구간의 확률을 구함

◆ 대표 연속 분포 & 시험 포인트

분포 이름	설명	사용 예	관련 검정
정규분포	종 모양, 평균 중심 대칭	키, 체중, 점수	Z-검정
t-분포	표본 적을 때 평균 비교	표본 수 적을 때 평균 비교	t-검정 (2집단 평균 차이 검정)
카이제곱분포	한쪽으로 치우친 종 모양	범주형 변수 독립성 검정	카이제곱검정
F-분포	두 집단의 분산 비교	분산이 같냐 다르냐 확인	F-검정 (분산비 검정)
지수분포	사건 사이 시간 간격	기계 고장까지 걸리는 시간	생존분석 등

⇒ 지수,카이,FT 정규 콘서트

✅ 시험에 자주 나오는 포인트

포인트	설명
t-분포는 표본 작을 때 사용 ($n < 30$)	$n \geq 30$ 이면 정규분포와 거의 같아짐
Z-검정은 모표준편차를 알고 있을 때 사용	모표준편차 모르면 → t-검정
카이제곱검정은 범주형 데이터에서 사용	독립성/적합도 검정
F-검정은 분산 비교에 사용	두 집단이 동질한지

• 표본집단의 표본분포

- 표본분포의 평균은 모집단의 평균과 같음
- 표본분포의 분산은 모집단의 분산을 표본 크기로 나눈 것과 같음

- 중심극한정리 : 표본 크기가 충분히 크면($n=30$) 모집단 분포에 상관없이 표본분포가 정규분포를 이룸

2. 추론통계

⇒ 전체 모집단을 다 조사하지 않고, 일부 표본을 바탕으로 전체를 추측하는 통계 방법

- 점추정 : 모집단이 특정 값으로 추정
- 구간추정 : 모집단이 특정 구간으로 추정 (95%, 99%를 가장 많이 사용)

• 모평균의 구간 추정

- 모집단 분산을 알고 있는 경우
- 모집단 분산을 모르는 경우 = 정규분포를 사용할 수 없음

▪ 자유도가 $n-1$ 인 t분포를 이용

(1) 모집단의 분산을 알고 있는 경우

$$\bar{X} - Z_{\frac{\alpha}{2}} \frac{\sigma}{\sqrt{n}} \leq \mu \leq \bar{X} + Z_{\frac{\alpha}{2}} \frac{\sigma}{\sqrt{n}}$$

- 신뢰수준 95% : $Z_{\frac{\alpha}{2}} = 1.960$

- 신뢰수준 99% : $Z_{\frac{\alpha}{2}} = 2.576$

(2) 모집단의 분산을 모르는 경우

- 자유도가 $n-1$ 인 t분포를 이용하여 신뢰구간을 추정

$$\bar{X} - t_{\frac{\alpha}{2}, n-1} \frac{s}{\sqrt{n}} \leq \mu \leq \bar{X} + t_{\frac{\alpha}{2}, n-1} \frac{s}{\sqrt{n}} \quad (s : \text{표본표준편차})$$

참고

• 가설검정 - 어떤 주장이 맞는지 아닌지 데이터로 확인하는 과정

: 모집단 특성에 대한 주장을 가설로 세우고 표본조사를 통해 가설의 채택여부를 판정

- 귀무가설(H_0) : 일반적으로 생각하는 가설 (기본 가설)
- 대립가설(H_1) : 증명하고자 하는 가설
- 유의수준(α) : 참인데 이것을 기각하게 될 확률 ex) 5% - 100번 중 5번 오류 허용
- 기각역 : 귀무가설을 버리기로 한 구간!
 - 양측 검정 : 기각역이 양쪽에 있음 예) 너무 크거나 너무 작을 때
 - 단측 검정 : 기각역이 한쪽에 있음 예) 너무 크기만 할 때

#귀무가설이 사실 - 거짓이라고 판정 = 1종 오류 (판매자 오류) 정상인데 반품 당함 😭

#귀무가설이 거짓 - 사실이라고 판정 = 2종 오류 (소비자 오류) 불량인데 정상인 줄 앎 😭

“올바른 결론을 내리긴 했지만, 잘못된 질문(가설)이나 방향으로 판단한 오류” = 3종 오류

★가설검정 문제 풀이 방법★

1. 귀무가설 / 대립가설 설정
2. 양측 혹은 단측검정 확인
 - 값이 '같지 않다' → 양측검정 / '값이 크다', '값이 작다' → 단측검정
3. 일표본 혹은 이표본 확인 (모집단이 하나인지 2개 이상인지)
4. 검정통계량 계산과 기각역 판단
5. t검정인 경우 단일 / 대응 / 독립표본 확인
 - 모집단에 대한 평균검정 : 단일표본
 - 동일 모집단에 대한 평균비교 검정 : 대응표본
 - 서로 다른 모집단에 대한 평균비교 검정 : 독립표본

A 공장에서의 제품의 불량률은 1.7%, 모표준편차 0.3%로 관리하고있다. 이 공장에서 9개의 샘플을 활용하여 분석하였더니 불량률이 평균 1.5%였다. 이 공장의 불량률을 1.7%로 관리하고 있다는 주장에 대해서 의문을 제기할 때, 5% 유의수준으로 가설검정을 수행 ($Z_{0.05} = 1.645, Z_{0.025} = 1.96$)
1) 귀무가설/대립가설 설정 - '차이가 없다' 혹은 '동일하다' → 귀무가설로 설정 - A공장의 불량률은 1.7%이다.
2) 양측 혹은 단측검정 확인 - 대립가설의 값이 같지 않다 → 양측검정
3) 일표본 혹은 이표본 확인 - 한개의 모집단 → 일표본
4) 검정통계량 계산과 기각역 판단 - 검정통계량 : $Z_o = (\bar{X} - \mu) / (\delta / \sqrt{n}) = (1.5 - 1.7) / (0.3 / \sqrt{9}) = -2.0$ - 기각역 : $\pm Z_{0.025} = \pm 1.96$ - 판정 : $Z_o < -1.96 \rightarrow$ 귀무가설 기각
(심화) 모표준편차를 모르는 경우 (표본표준편차가 0.3% 일 때) → t검정을 사용
1), 2), 3)은 동일
4) 검정통계량 계산과 기각역 판단 - 검정통계량 : $t_o = (\bar{X} - \mu) / (S / \sqrt{n}) = (1.5 - 1.7) / (0.3 / \sqrt{9}) = -2.0$ - 기각역 : $\pm t_{0.025, 8} = \pm 2.18$ - 판정 : $t_o > -2.18 \rightarrow$ 귀무가설 채택
5) 단일표본, 대응표본, 독립표본 확인 - 모집단에 대한 평균검정 → 단일표본

▼ 3과목

#분석모형 설계

1. 분석 절차 수립

- 과대적합 : 모델이 지나치게 데이터를 학습해 매우 복잡해진 모형
- 과소적합 : 데이터를 충분히 설명하지 못하는 단순한 모델

2. 분석 환경 구축

- 분석 도구 선정
 - R : 통계 분석에 특화, 처리속도 느림, 강력한 시각화

- Python : 간결함, 높은 가독성, R보다 빠른 속도, R보다 약한 시각화
- 데이터 분할 : 과대적합/과소적합 방지 및 데이터 불균형 문제 해결
 - 훈련용(Training) : 모델 학습 - 50%
 - 검증용(Validation) - 30%
 - 평가용(Test) : 모델 평가 - 20%

#분석기법 적용

1. 분석기법

- **회귀분석** : 독립변수가 종속변수에 미치는 영향을 파악 연속형/연속형
 - ⇒ 예측선 하나 그어놓고, 예측값이랑 진짜값이 얼마나 차이 나는지 보자
 - 잔차 : 예측값과 실제값 차이 (**오차는 모집단, 잔차는 표본 기준**)
 - 회귀계수 : 기울기랑 절편 → 얼마나 영향을 주나
 - 회귀계수 추정방법 : **최소제곱법** ⇒ 잔차 제곱 다 더한게 제일 작게되는 절편 찾기
 - 회귀모형 평가 : R-square (0~1 사이 값)
 - 예측 잘하면 1에 가까워짐 R^2 (결정계수)
- **선형 회귀분석의 가정 5가지**
 1. 선형성 : 종속-독립변수는 선형관계 (직선관계)
 2. 독립성 : 잔차와 독립변수 간 상관관계가 없음
 - * 다중공선성 : 독립변수 서로 간에 강한 상관관계가 나타나는 문제 → 차원 축소, 상관계수 분해 필요
 3. 정상성(정규성) : 잔차가 정규분포의 특성을 지님x
 4. 등분산성 : 잔차의 분산이 고르게 분포
 5. 비상관성 : 잔차들끼리 상관이 없어야 함
- 회귀 모형 변수 선택 방법
 - 전진선택법 - 하나씩 넣어보면서 성능 좋아지면 유지
 - 후진선택법 - 다 넣고 하나씩 빼면서 봄
 - 단계별 선택법 : 전진+후진
 - 벌점 기준 : 변수 추가 시 벌점(AIC, BIC - 낮을수록 👍) 고려
- **로지스틱 회귀분석** : 종속변수가 범주형 데이터일 때 쓰는 회귀 연속형/범주형
 - ⇒ 결과 값이 예/아니오처럼 뚜렷할 때 쓰는 회귀
 - 오즈 : 성공 확률과 실패 확률의 비
 - 로짓(logit) 변환 : 오즈에 자연로그를 취하여 선형처럼 바꿈
 - 독립변수가 n증가하면 확률이 e의 n승 만큼 증가
 - 확률 예측 모델이지만 선형회귀처럼 해석도 가능하
- **의사결정나무** : 여러 개 분리 기준으로 최종 분류 값을 찾음
 - ⇒ 질문하면서 나무처럼 가지를 쳐나가는 분류기

- 분할기준
 - 분류에서의 분할 방법 : CHAID(통계적 유의성), CART(지니지수), C4.5/C5.0(엔트로피지수)
 - 회귀에서의 분할 방법 : CHAID, CART
- 정지규칙 : 분리를 더 이상 수행하지 않게 함
- 가지치기 : 일부 가지를 제거하여 과적합 방지
- **인공신경망** : 인간의 뇌 구조를 모방한 퍼셉트론 활용
 - 퍼셉트론 - 신경망 기본 단위 (입력 → 가중치 → 활성화 함수 → 출력)
 - 다중 퍼셉트론(MLP) - 입력층~출력층 사이에 1개 이상의 은닉층 보유
 - *은닉층 수는 사용자가 직접 설정
 - 활성화 함수 : 인공신경망의 선형성 극복 (XOR 문제 해결)
 - ⇒ 입력신호의 총합을 출력신호로 변환하는 기능이 있는 부문
 - 시그모이드 함수 : 0~1 사이 값을 가지며 로지스틱 회귀분석과 유사
 - 소프트맥스 함수 : 목표 데이터가 다범주인 경우 각 범주에 속할 사후확률을 제공
 - 하이퍼볼릭 탄젠트 함수 : 시그모이드의 중심 값을 0으로 이동 → -1~1 사이 값
 - ReLU 함수 : 기울기 소실문제 극복 → 0 또는 1 둘 중 하나 값
 - 인공신경망 과적합 방지방안
 - ⇒ 공부 너무 외운 티 나면 실전에서 틀리듯, 모델도 똑같아
 - 라쏘(L1) 규제 : 맨하탄 거리 기반(절대값) - 변수가 일부 아예 제거됨
 - 릿지(L2) 규제 : 유클리드 거리 기반(제곱) - 변수의 영향을 줄이기 위해 0에 가깝게 만들
 - 드롭아웃 - 일부 퍼셉트론을 비활성화 (일부 뉴런 끄)
 - 조기종료 - 성능 나빠지기 전에 꺼버림
 - 모델의 복잡도 줄이기 - 은닉층의 퍼셉트론 감소
 - 데이터 증강 - 데이터를 더 많이 만들기
 - 배치정규화 - 중간 중간 정규화해서 안정화
 - 인공신경망 학습 방법
 - 역전파 알고리즘 : 가중치를 수정하여 오차를 줄임 (출력층 → 입력층)
 - 경사하강법 : 기울기를 낮은 쪽으로 이동시켜 극값(global minimum)에 이를 때까지 반복
- **서포트벡터머신(SVM)** : 마진이 최대가 되는 초평면(경계선)을 찾아 분류
 - ⇒ 데이터를 가장 똑 떨어지게 나눌 수 있는 '경계선' 찾기
 - 초평면(하이퍼플레인) : 데이터를 구분하는 기준이 되는 경계선
 - 서포트벡터 : 초평면(경계선)과 가장 가까운 데이터들
 - 마진 : 초 평면(하이퍼플레인)과 서포트벡터 사이의 거리 → 최대화 목표
 - 커널함수 : 저차원 데이터를 고차원 데이터로 변경하는 함수
 - 유형

1. 하드마진분류 : 오류 비허용 - 절대 틀리지 마
2. 소프트마진분류 : 마진 내 어느 정도 오류 허용 - 어느정도는 뭐 ~

- **연관분석** : 항목들 간 조건-결과로 이뤄지는 패턴 발견 기법 **Apriori 알고리즘**

⇒ 이거 사면 저것도 잘 사더라 (장바구니 분석)

- 결과가 단순, 분명
- 품목 수 많을수록 계산이 기하급수적으로 증가
- **Apriori 알고리즘 활용**
- 연관분석의 **지표** (하단 공식 암기 부분에 기재)
 1. **지지도** - A와 B를 **동시에** 살 확률
 2. **신뢰도** - A 샀을 때 B도 샀을 확률
 3. **향상도** - 우연이 아니고 진짜 관련 있나 ?

- **군집분석** : 비지도 학습, 데이터 간 거리나 유사성을 기준으로 군집 나눔

⇒ 비슷한 애들끼리 알아서 뭉쳐보자 (답 없음)

- 거리 기준
 1. **연속형 변수**
 - **유클리디안 거리** : 직선 거리, 차이의 제곱의 합의 루트
 - **맨하튼 거리** : 계단식, 차이의 절대값의 합
 - **체비셰프 거리** : 최댓값, 차이의 절대값 중 최댓값
 - 표준화 거리 : 유클리디안 거리를 표준편차로 나눔
 - 민코프스키 거리 : **일반화**, 유클리드/맨하튼 거리를 일반화
 - 마할라노비스 거리 : **상관관계까지 반영**, 표준화 거리에서 변수의 **상관성** 고려
 2. 범주형 변수 - 자카드 유사도, 코사인 유사도
- **계층적** 군집분석
 1. 거리측정 방법 : 최단, 최장, 평균, 중심, 와드
 2. 덴드로그램 (Tree 모양 그래프)
- **비계층적** 군집분석
 1. **K평균 군집화**
 - 지정된 군집 개수에 따라 평균을 기준으로 중심점 설정 → 중심점 변경 시 군집 변할 수 있음
 - 이상치에 민감 → 이에 대응하기 위해 K-medoids 군집방법 존재
 2. **DBSCAN**
 - 밀도기반, 군집수 미정
 - 노이즈 / 이상치에 강함
 3. 기타
 - a. 퍼지군집화
 - b. EM알고리즘
 - c. 자기조직화지도(SOM) : 신경망 활용하여 차원축소(고차원 → 저차원)를 통해 군집화

2. 고급 분석기법

- 분할표 : 여러 개 범주형 변수를 기준으로 관측치 기록한 표 (오즈비 계산)

- **다변량 분석**

⇒ **다변량 데이터들은 분석할 때 차원축소!**

- **요인분석** : 다수 변수들의 **상관관계를 분석하여 소수 요인으로 축약**하는 기법

→ 독립, 종속 개념 X / 기술 통계 기반 (공분산, 상관계수)

→ 변수들이 같은 요인끼리 묶이고, 각 **요인끼리는 서로 독립적** (직교)

1. 요인추출방법 : 주성분분석, 공통요인분석
2. 요인회전

- **시계열 분석** : 시간 흐름에 따라 관찰된 자료 특성을 파악하여 미래 예측

- **정상성** = **모든 시점에 일정한 평균과 분산**을 가져야 함

* **차분** : 현 시점의 자료를 이전 값으로 빼는 방법

* **자기상관** : 현재 상태가 과거&미래와 밀접한 관련이 있음

⇒ 독립적이지 않음 (시계열 데이터에서의 공분산 기법)

- 백색잡음 : 시계열 모형의 오차항 의미

- 시계열 모형

1. 자기회귀(AR) 모형 : 자신의 과거 값이 미래를 결정

2. 이동평균(MA) 모형 : 백색잡음들의 선형결합으로 표현 (관측치에 모두 동일 가중치 부여)

* **지수평활법** : MA 종류 중 하나로, **최근 관측치**에 더 높은 가중치를 부여

3. 자기회귀누적이동평균(ARIMA) 모형 = AR + MA

: ARIMA (p, d, q)에서 d는 차분 횟수를 의미

- 분해시계열 - 시계열에 영향을 주는 요인을 분리해 해석하는 방법

1. 추세 요인 : 장기적으로 증가하거나 감소
2. 계절 요인 : 특정 시기에 나타나는 고정된 주기
3. 순환(주기, cycle) 요인 : 알려지지 않은 주기, 중장기적
4. 불규칙 요인 : 설명 불가 요인

- **베이지안 기법 사전확률 → 새로운 증거 → 사후확률**

⇒ 새로운 정보가 생기면 확률도 바뀌어야지?

- 베이즈 정리 (하단 공식 암기에 기재)
- 나이브베이즈 분류 = 나이브(독립) + 베이즈 이론

- 인공지능망

- **심층 신경망** (Deep Neural Network, **DNN**) : 은닉층 **2개** 이상으로 구성된 인공지능망

- 다층 퍼셉트론(MLP) 구조
- 시계열 이미지 등 특수 구조에 약함

- **합성곱 신경망** (Convolutional Neural Network, **CNN**) : 이미지에서 패턴을 찾음

- 얼굴 인식, 사진 분류, 자율주행 카메라에 활용

- **순환 신경망** (Recurrent Neural Network, **RNN**): 순차적 데이터(시계열 데이터) 학습에 특화
 - 이전 입력을 기억하여 현재 입력과 함께 처리
 - 문장, 주가, 날씨, 음성, 필기체 등 순서가 중요한 데이터에 활용
 - **단점 : 장기 의존성** 오래된 정보는 잘 기억하지 못함
⇒ **LSTM / GRU** 모델(Reset, Update)로 극복
- **오토인코더** : 입력 데이터를 인코더로 압축한 후 디코더로 재구성하는 비지도 학습 신경망 **비지도학습**
- **텍스트 마이닝 - 문자 데이터도 분석할 수 있음**
 - 통계적 기반
 1. TDM : 문서에서 등장하는 단어들의 빈도를 행렬로 표현
 2. TF-IDF : 단어 등장 빈도를 특정 문서, 전체 문서에서 비교하는 것
 - 단어 수준 기반
 1. Word2Vec : 거리를 기반으로 하여 벡터로 표현 ~ CBOW, Skip-Gram
 2. FastText : 하나의 단어를 여러 개로 잘라서 벡터로 계산
 3. ELMo : 양방향 언어 모델 적용
- **트랜스포머** : RNN의 느린 속도와 병렬 처리 불가 단점을 개선한 모델 (BERT, GPT)
- **앙상블 분석** : 여러 개의 예측 모형들을 조합 → 전체적인 **분산을 감소**시켜 성능 향상
⇒ 혼자보다 같이 가 낫다! ⇒ 여러개 예측 모형 ⇒ 전체적인 분산 감소
 1. **보팅** : 다수결 방식
 2. **배깅** : 복원추출하는 붓스트랩으로 **학습 후 보팅으로 결합 / 데이터 무작위 추출 + 병렬 학습**
 3. **부스팅** : 틀린 거에 더 집중해서 학습 (순차적) **이상치에 민감, 병렬처리 불가**
 4. 랜덤포레스트 : 배깅 + 의사결정트리 ⇒ 성능 우수하며 이상치에 강함
- **비모수검정**
 - ⇒ 분포 모르니까 그냥 순서나 차이로 비교하자
 - 모집단에 대한 정보가 없을 때, 관측 자료의 분포 가정 불가능한 상태일 때
 - 두 관측 간 순위나 차이로 검정
 - 종류 : 부호검정, 순위합검정, 만-휘트니 U검정, 크루스칼-윌리스 검정

▼ 4과목

#분석모형 평가 및 개선

1. 분석모형 평가

- **분류모델 평가지표**
 1. **☆ 혼동행렬(오분류표)**
 - 재현율(Recall) = 민감도(sensitivity) = TP Rate = Hit Rate
 - F-1 Score는 정밀도(Precision)와 재현율(Recall)의 조화평균
 - 특이도(Specificity) : 실제 False인 것 중 맞춘 것

- 정밀도와 재현율은 Trade-off 관계

2. ROC 커브

- 가로축 = 1-특이도 (=FP Rate), 세로축 = 민감도
- 면적이 1에 가까울수록 성능 좋다고 평가

3. 이익 도표(Lift Table)

- 불균형 데이터 집합에 사용, 성과 향상도를 각 등급별로 파악할 수 있음
- 향상도 곡선 : 이익도표를 시각화한 곡선

• 회귀모델 평가지표

1. 손실함수(비용함수) : MSE, MAE, RMSE... 등
2. 결정계수(R square) → 0~1 사이 값

• 군집분석 평가지표

⇒ 군집 내 유사, 군집 간 분리

1. 실루엣 계수

- 실루엣 지표가 1에 가까울수록 잘 된 군집화 (0.5보다 크면 타당한 것으로 평가)

2. Dunn Index(DI) : 클수록 군집화 잘 되었다고 평가

• 교차 검증

1. 홀드아웃 : 훈련용, 평가용 데이터셋 분리
2. K-fold 교차검증 : 데이터를 k개 집단으로 구분하여 **k-1개 학습, 나머지 1개로 평가**
3. LOOCV : 1개의 데이터로만 평가, 나머지로 학습
4. 붓스트랩 : 복원추출 (데이터 부족과 불균형 문제 해소)

• 적합도 검정

1. Q-Q plot : 데이터 정규성을 시각적으로 파악 (대각선 선을 따라 값들이 분포하면 정규성 만족)
2. 카이제곱 검정
3. 샤피로 윌크 검정 : 선형상관관계를 측정하여 검정, p-value 0.05보다 크면 정규성 가정
4. 콜모고로프-스미르노프 검정 : 누적 분포함수 비교한 연속형 데이터 검정, p-value 0.05보다 크면 정규성 가정





2. 분석모형 개선

• 하이퍼 파라미터

1. 경사하강법 : a가 너무 크면 값이 높은 곳으로 발산, 너무 작으면 오랜 시간이 걸림
2. Batch Size : 하나의 소그룹에 속하는 데이터 수
 - Epoch - 모든 데이터셋을 학습하는 횟수
 - Iteration - Epoch를 한 번 마치기 위해 필요한 배치 수
- 하이퍼파라미터 튜닝
 - : 메뉴얼 서치(경험 또는 감으로 설정), 그리드 서치, 랜덤 서치, 베이지안 최적화 (기존 평가 결과를 활용)

• 경사하강법 옵티마이저

1. 확률적 경사 하강법 : 기울기가 가장 작은 지점에 도달하도록 함
2. 모멘텀 : 관성 물리법칙 적용, 빠른 최적점 수렴 가능
3. AdaGrad : 기울기 크기에 따라 학습률을 조정 / 처음엔 크게 → 점차 작게 학습
4. Adam : 모멘텀+AdaGrad ⇒ 좌우 흔들림이 덜함

확률적 경사 하강법	모멘텀	AdaGrad	Adam
SGD; Stochastic Gradient Descent	Momentum	Adaptive Gradient Algorithm	Adaptive Moment Estimation
			
- 먼저 손실함수 기울기 구함 → 기울기따라 조금씩 아래로 → 손실함수 최소 지점 도달 - 최적점 근처에서 느리게 진행	- 모멘텀 = SGD + 속도 - 기울기방향으로 가속됨	- 학습률 감소 기법을 적용 - 기울기 큰 부분에서 크게 학습 - 최적점에 가까워질수록 학습률 줄임→조금씩적게 학습	- Adam = 모멘텀 + AdaGrad - 탐색경로 또한 모멘텀과 AdaGrad를 합친 양상
경로: 지그재그로 크게 변함	공이 그릇 바닥을 구르듯 움직임 지그재그 정도 덜함	처음에 큰폭이었다가 → 갱신 움직임 크게 줄어듦	공이 그릇 바닥을 구르듯 움직임 모멘텀보다 좌우 흔들림 적음

#분석결과 해석 및 활용

1. 분석결과 해석

↳ 문제푸는 방법 위주 설명

- 주성분 분석 (PCA)

(1) 주성분 분석의 결과 해석

<pre>> result<-prcomp(data,center=T,scale=T) > summary(result)</pre>							
	PC1	PC2	PC3	PC4	PC5	PC6	PC7
Standard deviation	2.1119	1.0928	0.72181	0.67614	0.49524	0.27010	0.2214
Proportion of Variance	0.6372	0.1706	0.07443	0.06531	0.03504	0.01042	0.0070
Cumulative Proportion	0.6372	0.8078	0.88223	0.94754	0.98258	0.99300	1.0000
- 첫번째 주성분(PC1)의 분산(0.6372)이 가장 큼 - 두 개의 주성분(PC1, PC2)을 적용하면 전체 데이터의 약 80%를 설명							

- 스크리플롯 : 주성분 개수 선택 시 도움이 되는 그래프 (팔꿈치 기법 이용)

⇒ 그래프가 완만해지기 직전 단계 개수로 선택

- ★회귀모형의 검정결과

1. 모형이 통계적으로 유의미한가 : F통계량, p-value

- 귀무가설 : '모든 회귀계수는 0이다'

2. 회귀계수들이 유의미한가 : t통계량, p-value

- 귀무가설 '회귀계수는 0이다'

3. 1번과 2번 모두 귀무가설 기각되면 해당 모델 활용

4. 모형이 설명력을 갖는가 = 결정계수(R square) 값

신경망(DNN, CNN, RNN)	복잡한 예측 문제	모든 형태 가능	이미지, 시계열, 텍스트
SVM	고차원 분류	연속형 / 범주형	경계 기준 분류
시계열분석 (ARIMA 등)	시간 데이터 예측	시간 / 연속형	매출 예측, 주가 예측
베이지안 분석	사전 확률 + 데이터 → 사후확률	다양한 경우	스팸 필터, 질병 확률

💡 변수 형태로 분석기법 빠르게 고르는 팁

독립변수	종속변수	분석 방법
연속형	연속형	선형회귀
연속형	범주형	로지스틱 회귀분석 ✅
범주형	연속형	분산분석(ANOVA)
범주형	범주형	교차분석, 로지스틱 회귀, 카이제곱
시계열	연속형	시계열분석(ARIMA 등)

필요하면 분석 기법 선택 흐름도도 만들어줄 수 있어요!

또 다른 분석 방법 헛갈리는 거 있으면 언제든지 물어봐 😊

▼ 2025/04/03 D-1 복습

📖 복습 요약 정리

✅ 1. 기각역 & 가설검정 핵심

- 귀무가설(H_0): 기본 주장 ("차이 없다", "변화 없다")
- 대립가설(H_1): 연구자가 증명하고 싶은 주장
- 기각역: 검정통계량이 이 안에 들어가면 → H_0 기각
- 임계값: 기각역의 경계값
- 유의수준(α): 1종 오류 허용 한계 (보통 0.05)

📌 오류 구분

- 1종 오류: H_0 맞는데 기각 (판매자 오류)
- 2종 오류: H_0 틀렸는데 채택 (소비자 오류)

✅ 2. 요약변수 vs 파생변수

구분	정의	예시
요약변수	여러 개 값을 하나로 집계	고객별 총 구매금액, 평균기온
파생변수	기존 변수 가공/조합	나이 = 올해 - 출생연도, VIP 여부

📌 요약변수는 데이터 마트의 기본 변수로,

→ 범용성/재활용성 높고, 분석에 자주 쓰임

✅ 3. 결측치 구분

유형	설명	예시
MCAR (완전 무작위)	아무 조건 없이 랜덤	설문지 인쇄 오류
MAR (조건부 무작위)	다른 변수와 관련 있음	여성이 체중 입력을 꺼림
NMAR (비무작위)	결측 변수 자체와 관련 있음	살찐 사람일수록 체중 안 적음

✅ "젊은 여성이 체중 공개 꺼림" → NMAR(비무작위)

✅ 4. 요인분석 vs 주성분분석 (PCA)

구분	주성분분석(PCA)	요인분석(Factor)
목적	데이터 요약, 차원 축소	숨겨진 요인 찾기, 원인 해석

수학 기반	단순 수학 변환	통계 모형 기반
사용 시기	정보 줄이고 싶을 때	변수 간 구조 분석할 때

📌 PCA는 분산 보존, 요인분석은 의미 있는 요인 해석

✅ 군집추출

전체를 **무리(그룹)**로 나눈 뒤,

몇 개 군집만 뽑아서 조사

- 예: 학교 전체 → 몇 개 학교만 골라 학생 전체 조사
- ✓ 전체에서 일부 “그룹 단위”로 추출

✅ 신뢰구간

“진짜 평균이 이 구간 안에 있을 확률이 95%쯤 된다”

📌 빠른 계산 팁:

- 보기 중 숫자 범위가 가장 가까운 게 정답
- 예: 평균 97, 표준편차 7, 표본 5 → 대략 (90~103) 근처

✅ 질적/수치 자료 + 횡단/종단

구분	하위	설명	예시
질적자료	명목형	이름/구분	성별, 혈액형
	순서형	순서는 있음	만족도(상/중/하)
수치자료	구간형	차이는 의미 O, 0 기준 없음	온도(섭씨), 연도
	비율형	차이 + 비율 의미 O, 0 있음	키, 나이, 소득
자료형태	횡단자료	한 시점, 여러 사람	2023년 학생 키
	종단자료	한 사람, 여러 시점	2019~2023년 한 학생 키 변화

✅ 확률분포 총정리

◆ 이산 확률분포 (PMF, 셀 수 있음)

분포	키워드	기억법
베르누이	1회 성공/실패	베
이항분포	성공/실패 n번 반복	베 + 반복
기하분포	처음 성공까지 시도 횟수	처음 성공
다항분포	여러 범주	복수 결과
포아송분포	단위 시간/공간 내 사건 수	희귀 사건

📌 외우기: 베포항항하 (베르누이 → 포아송 → 이항 → 기하 → 다항)

◆ 연속 확률분포 (PDF, 셀 수 없음)

분포	특징	관련 검정
정규분포	종 모양, 대칭	Z-검정
t-분포	표본 수 적을 때	t-검정 (평균 비교)
카이제곱분포	비대칭, 범주형	독립성/적합도 검정
F-분포	분산 비교	분산동질성 검정
지수분포	사건 간 시간	생존분석 등

📌 t-분포는 표본 수 많아지면 → 정규분포와 유사해짐

📌 Z-검정은 모표준편차를 알고 있을 때만 사용