

제 1과목 : 빅데이터 분석 기획

1. 빅데이터 분석과 관련된 기술에 대한 설명으로 가장 옳지 않은 것을 고르세요.

- ① R, Python 등은 통계 분석과 머신러닝 모델 구현에 널리 사용되는 프로그래밍 언어이다.
- ② JDBC(Java Database Connectivity)와 OLAP(Online Analytical Processing)은 모두 데이터 분석을 수행하는 핵심 도구이다.
- ③ 하둡(Hadoop)은 대용량 데이터를 분산 처리하기 위한 대표적인 프레임워크이다.
- ④ 스파크(Spark)는 인메모리(In-Memory) 기반의 고속 데이터 처리 엔진이다.

2. 기업의 데이터 분석 조직 구조 중 '집중형 구조'의 특징으로 볼 수 없는 것을 고르세요.

- ① 전사적 관점에서의 분석 수행 및 표준화에 유리하다.
- ② 분석 결과를 현업 부서의 업무에 가장 빠르게 적용할 수 있다.
- ③ 분석 전문 인력과 기술을 한곳에 모아 역량을 극대화할 수 있다.
- ④ 현업 부서의 분석 요청이 몰릴 경우 병목 현상이 발생할 수 있다.

3. 개인정보의 처리 및 활용에 대한 설명으로 가장 틀린 것을 고르세요.

- ① 개인정보는 수집 목적과 관계없이 항상 가명 또는 익명 처리를 한 후에 사용해야 한다.
- ② 정보 주체의 동의를 받은 경우, 수집 목적 범위 내에서 개인정보를 그대로 이용할 수 있다.
- ③ 통계 작성, 과학적 연구 등을 위해 정보를 활용할 경우 가명 처리를 통해 안전하게 활용할 수 있다.
- ④ 익명 처리는 개인을 알아볼 수 없도록 처리하는 것으로, 개인정보 보호법의 적용을 받지 않는다.

4. 빅데이터 시대의 역기능 중 '책임 원칙 위배'에 해당하는 사례로 가장 적절한 것을 고르세요.

- ① 알고리즘의 편향성으로 인해 특정 집단에 대한 차별적인 결과가 도출되었다.
- ② 데이터 분석 결과에 대한 소유권 및 저작권 분쟁이 발생하였다.
- ③ '빅브라더'와 같이 국가나 기업이 개인의 일상을 감시하고 통제한다.
- ④ 데이터의 양이 너무 방대하여 저장하고 관리하는 데 많은 비용이 소요된다.

5. 데이터 분석 방법론의 '분석 기획' 단계에서 수행되는 절차를 올바른 순서대로 나열한 것을 고르세요.

- ① 비즈니스 이해 및 범위 설정 → 프로젝트 정의 및 계획 수립 → 프로젝트 위험 관리 계획 수립
- ② 프로젝트 정의 및 계획 수립 → 비즈니스 이해 및 범위 설정 → 프로젝트 위험 관리 계획 수립
- ③ 프로젝트 위험 관리 계획 수립 → 비즈니스 이해 및 범위 설정 → 프로젝트 정의 및 계획 수립
- ④ 비즈니스 이해 및 범위 설정 → 프로젝트 수행 → 프로젝트 위험 관리 계획 수립

6. 개인정보를 특정 그룹 단위로 합산하여 요약하는 '총계처리'에 대한 설명으로 가장 틀린 것을 고르세요.

- ① 총계처리된 데이터에서는 특정 개인을 식별할 수 없다.
- ② '서울 거주 30대 남성의 평균 소득'은 총계처리의 예시이다.
- ③ 총계처리를 하면 데이터의 재현성이 높아져 항상 동일한 분석 결과가 나온다.
- ④ 개인정보를 안전하게 활용하기 위한 비식별 조치 기술 중 하나이다.

7. 데이터 유형에 대한 설명으로 가장 옳지 않은 것을 고르세요.

- ① 정형 데이터는 관계형 데이터베이스(RDBMS)에 저장된 테이블처럼 고정된 스키마를 가진다.
- ② 비정형 데이터는 텍스트, 이미지, 동영상 등 정해진 구조가 없는 데이터를 의미한다.
- ③ 반정형 데이터(XML, JSON 등)는 데이터의 구조나 형태를 유연하게 변경할 수 없다.
- ④ 데이터 분석을 위해서는 비정형 또는 반정형 데이터를 정형화하는 과정이 필요한 경우가 많다.

8. 빅데이터 플랫폼에서 하드웨어 자원을 배치하고 관리하는 노드(Node) 및 관련 자원 관리 모듈(예: YARN)이 속하는 계층으로 가장 적절한 것을 고르세요.

- ① 인프라스트럭처 계층 (Infrastructure Layer)
- ② 데이터 수집 계층 (Data Ingestion Layer)
- ③ 데이터 처리 계층 (Data Processing Layer)
- ④ 데이터 분석 계층 (Analytics Layer)

9. 웹 환경에서 데이터를 수집하는 방법과 그에 대한 설명이 잘못 연결된 것을 고르세요.

- ① 크롤링(Crawling) : 자동화된 봇(Bot)을 이용하여 웹 페이지의 링크를 따라다니며 정보를 수집한다.
- ② API(Application Programming Interface) : 서비스 제공자가 정해진 규격에 따라 데이터를 제공하면 이를 호출하여 수집한다.
- ③ FTP(File Transfer Protocol) : 웹 서버의 활동 기록인 웹 로그 데이터를 실시간으로 스트리밍하여 수집한다.
- ④ 스크레이핑(Scraping) : 특정 웹 페이지에서 원하는 부분의 데이터를 추출하여 수집한다.

10. 데이터의 품질 특성에 대한 설명으로 가장 옳지 않은 것을 고르세요.

- ① 일관성 : 동일한 데이터가 시스템 전반에서 내용과 형식이 일치되게 표현되어야 한다.
- ② 정확성 : 데이터는 현실 세계의 사실을 정확히 반영하고, 오류나 왜곡 없이 입력되어야 한다.
- ③ 적시성 : 데이터는 사용자가 필요로 하는 시점에 적절하게 제공되어야 한다.
- ④ 완전성 : 데이터는 사용자의 주관적인 판단에 따라 필요한 정보만 선택적으로 구성되어야 한다.

11. 개인정보의 일부를 삭제하거나 대체하는 등의 방법으로 처리하여, 그 정보만으로는 특정 개인을 알아볼 수 없지만 다른 정보와 쉽게 결합하여 알아볼 수 있는 정보를 무엇이라고 하는가?

- ① 가명정보
- ② 익명정보
- ③ 암호정보
- ④ 비정형정보

12. 빅데이터 플랫폼을 '인프라'와 '서비스'로 구분할 때, '서비스'에 해당하는 것으로 가장 적절한 것을 고르세요.

- ① 분산 파일 시스템(HDFS)
- ② 데이터 처리 프레임워크(Spark)
- ③ 분석 결과를 API 형태로 제공

④ 클러스터를 구성하는 물리 서버

13. 분석 과제의 유형을 '분석 대상(What)'과 '분석 방법(How)'의 인지 여부에 따라 4가지로 분류할 때, '분석 방법은 알고 있지만 분석 대상을 명확히 모르는 상태에서 새로운 통찰을 발견하는' 유형은 무엇인가?

- ① 최적화 (Optimization)
- ② 통찰 (Insight)
- ③ 해결 (Solution)
- ④ 발견 (Discovery)

14. 데이터 웨어하우스(Data Warehouse)의 핵심적인 4대 특징에 해당하지 않는 것을 고르세요.

- ① 주제 지향성 (Subject-Oriented)
- ② 통합성 (Integrated)
- ③ 시계열성 (Time-Variant)
- ④ 확장성 (Scalability)

15. 특정 문제 해결을 위해 대규모 데이터로 미리 학습시켜 놓은 모델(Pre-trained Model)을 가져와, 유사하지만 새로운 문제 해결에 재사용하여 학습 효율과 성능을 높이는 머신러닝 기법은 무엇인가?

- ① 강화학습 (Reinforcement Learning)
- ② 전이학습 (Transfer Learning)
- ③ 준지도학습 (Semi-supervised Learning)
- ④ 앙상블 학습 (Ensemble Learning)

16. 개인정보 보호법에서 규정하는 개인정보 처리 원칙으로 가장 옳지 않은 것을 고르세요.

- ① 정보 주체의 권리가 침해받을 가능성과 그 위험 정도를 고려하여 개인정보를 처리해야 한다.
- ② 개인정보의 처리 목적을 명확히 해야 하고 그 목적에 필요한 범위에서 최소한의 개인정보만을 적법하게 수집해야 한다.
- ③ 수집한 개인정보는 최대한 오랫동안 보관하여 향후 발생할 수 있는 모든 상황에 대비해야 한다.
- ④ 개인정보를 처리하는 과정에서 정보 주체의 사생활 침해를 최소화하는 방법을 선택해야 한다.

17. 데이터 사이언티스트의 주요 역할 및 요구 역량으로 가장 거리가 먼 것을 고르세요.

- ① 복잡한 비즈니스 문제를 정의하고 데이터 기반의 해결 방안을 설계하는 능력
- ② 데이터 정제, 모델링, 알고리즘 구현 등 데이터 분석 전반에 대한 기술적 전문성
- ③ 분석 결과를 비전문가도 이해할 수 있도록 명확하게 전달하고 설득하는 커뮤니케이션 능력
- ④ 데이터 분석 조직의 예산을 편성하고 관련 인력의 채용 및 평가를 전담하는 관리 능력

18. 데이터 분석 프로젝트에서 전체 업무 범위를 세부적인 작업 단위로 계층적으로 분해하여 관리하는 'WBS(Work Breakdown Structure)'는 주로 어느 단계에서 활용되는 도구인가?

- ① 분석 주제 발굴 단계
- ② 데이터 수집 및 저장 단계

- ③ 분석 계획 수립 단계
- ④ 모델링 및 결과 해석 단계

19. 다음 중 정성적 데이터 수집 방법인 'FGI(Focus Group Interview)'에 대한 설명으로 가장 옳은 것을 고르세요.

- ① 대규모 응답자에게 구조화된 설문지를 배포하여 통계적인 데이터를 수집한다.
- ② 특정 주제에 대해 전문가나 소수의 응답자를 한자리에 모아 토의를 통해 심층적인 의견을 수집한다.
- ③ 실험 집단과 통제 집단으로 나누어 특정 처치의 효과를 통계적으로 검증한다.
- ④ 과거의 문헌이나 기록을 분석하여 역사적 사실이나 추세를 파악한다.

20. 에이전트(Agent)가 환경(Environment)과 상호작용하며 보상(Reward)을 최대화하는 방향으로 행동 정책(Policy)을 학습하는 머신러닝 기법에 대한 설명으로 가장 옳지 않은 것을 고르세요.

- ① 정답이 라벨링된 대규모 데이터셋을 통해 명시적인 규칙을 학습한다.
- ② 시행착오(Trial and Error)를 통해 최적의 행동을 학습해 나간다.
- ③ 대표적인 알고리즘으로 Q-러닝(Q-Learning), SARSA 등이 있다.
- ④ 순차적인 의사결정 문제(Sequential Decision Making)에 주로 적용된다.

제 2과목 : 빅데이터 탐색

21. 데이터 분석 모델을 구성할 때, 하나의 '변수(Variable)'로 사용할 수 없는 개념은 무엇인가?

- ① 고객의 나이
- ② 상품의 가격
- ③ 두 변수 간의 상관관계
- ④ 구매 여부(Yes/No)

22. 성공 확률이 p 인 베르누이 시행을 n 번 독립적으로 반복할 때, 성공 횟수 X 가 따르는 확률 분포는 이항분포 $B(n, p)$ 이다. 이 분포의 분산(Variance)으로 옳은 것을 고르세요.

- ① np
- ② $n(1-p)$
- ③ $np(1-p)$
- ④ $p(1-p)$

23. 모집단에서 크기가 n 인 표본을 추출할 때, 표본평균($\bar{X}$)의 통계적 성질에 대한 설명으로 항상 옳은 것을 고르세요.

- ① 표본평균의 기댓값 $E(\bar{X})$ 는 모평균(μ)과 같다.
- ② 표본평균의 분산 $Var(\bar{X})$ 은 모분산(σ^2)과 같다.
- ③ 표본의 크기 n 이 커질수록 표본평균의 기댓값은 0에 가까워진다.
- ④ 표본평균은 항상 정규분포를 따른다.

24. 데이터 {100, 200, 300}을 표준화(Z-score)하여 새로운 변수 **Z**를 만들 때, 변환식 $Z = aX + b$ 가 사용되었다. 이때 $a + b$ 의 값은? (단, 표준편차는 표본표준편차를 사용한다.)

- ① -2.01
- ② -2.00
- ③ -1.99
- ④ -1.98

25. 데이터 탐색 및 전처리 과정에서 기존 변수를 가공하여 새롭게 만드는 '파생변수'의 예시로 가장 적절한 것을 고르세요.

- ① 고객의 성별을 나타내는 원본 데이터
- ② 제품의 고유 식별 번호(ID)
- ③ 고객의 최근 1년간 평균 구매 금액
- ④ 데이터 수집 시 발생한 결측치

26. 확률변수 **X**가 $P(X=1) = p$, $P(X=-1) = 1-p$ 의 확률분포를 가질 때, **X**의 기댓값 $E(X)$ 는 무엇인가?

- ① 1
- ② p
- ③ $p - 1$
- ④ $2p - 1$

27. 텍스트 데이터에서 단어와 문서 간의 잠재적인 의미 관계를 분석하기 위해, 단어-문서 행렬(TDM)에 '특이값 분해(SVD)'를 적용하는 자연어 처리 기법은 무엇인가?

- ① Word2Vec
- ② LSA (Latent Semantic Analysis)
- ③ TF-IDF
- ④ LDA (Latent Dirichlet Allocation)

28. 데이터의 분포를 시각화하는 상자그림(Box Plot)에서 사용되는 사분위수 범위(IQR, Interquartile Range)에 대한 설명으로 가장 옳은 것을 고르세요.

- ① 데이터의 최댓값에서 최솟값을 뺀 값이다.
- ② 제3사분위수(Q3)에서 제1사분위수(Q1)를 뺀 값이다.
- ③ 데이터의 평균으로부터의 편차를 모두 더한 값이다.
- ④ 데이터 값들을 오름차순으로 정렬했을 때 중앙에 위치하는 값이다.

29. 모집단을 여러 개의 군집(Cluster)으로 나눈 후, 일부 군집을 무작위로 선택하여 선택된 군집 내의 모든 대상을 조사하는 표본추출방법은 무엇인가? (단, 이 방법이 효율적이려면 각 군집은 모집단의 축소판처럼 '내부적으로는 이질적'이고, 군집들 '간에는 동질적'이어야 한다.)

- ① 단순 무작위 추출 (Simple Random Sampling)
- ② 층화 추출 (Stratified Sampling)

- ③ 계통 추출 (Systematic Sampling)
- ④ 군집 추출 (Cluster Sampling)

30. 클래스 불균형(Class Imbalance) 문제를 처리하기 위한 샘플링 기법에 대한 설명으로 가장 옳지 않은 것을 고르세요.

- ① 언더샘플링은 다수 클래스의 데이터 수를 소수 클래스에 맞춰 줄이는 방법이다.
- ② 오버샘플링은 소수 클래스의 데이터 수를 다수 클래스에 맞춰 늘리는 방법이다.
- ③ SMOTE는 소수 클래스 데이터를 단순히 복제하는 오버샘플링 기법이다.
- ④ 데이터가 매우 클 때는 정보 손실을 감수하고 언더샘플링을 고려할 수 있다.

31. 모수(Parameter)를 추정하는 통계적 방법에 대한 설명으로 가장 옳은 것을 고르세요.

- ① 점추정은 모수가 특정 값일 것이라고 단정하는 방법이므로 신뢰수준을 항상 100%로 설정한다.
- ② 구간추정은 점추정 결과와 상관없이 독립적으로 모수가 포함될 범위를 계산한다.
- ③ 구간추정은 점추정치를 기준으로 신뢰수준 하에서 모수가 포함될 것으로 기대되는 범위를 제공한다.
- ④ 점추정은 항상 모수와 정확히 일치하는 값을 제공한다.

32. 오른쪽으로 길게 꼬리를 가지는(positively skewed) 데이터 분포에서 평균, 중앙값, 최빈값의 일반적인 크기 관계를 올바르게 나타낸 것을 고르세요.

- ① 평균 < 중앙값 < 최빈값
- ② 평균 < 최빈값 < 중앙값
- ③ 최빈값 < 평균 < 중앙값
- ④ 최빈값 < 중앙값 < 평균

33. N개의 제품 중 K개의 불량품이 포함된 상자에서 n개의 제품을 비복원추출로 뽑을 때, 나오는 불량품의 개수 X가 따르는 확률분포는 초기하분포이다. 이 분포의 특징으로 가장 옳은 것을 고르세요.

- ① 매 시행은 서로 독립적이다.
- ② 복원추출을 가정한다.
- ③ 매 시행의 성공 확률은 일정하지 않다.
- ④ 시행 횟수 n은 무한히 클 수 있다.

34. 두 변수 간의 선형 관계를 측정하는 상관계수의 특징에 대한 설명으로 가장 옳지 않은 것을 고르세요.

- ① 피어슨 상관계수는 이상치(outlier)의 영향을 크게 받지 않아 안정적이다.
- ② 상관계수는 -1과 1 사이의 값을 가진다.
- ③ 스피어만 상관계수는 변수의 실제 값이 아닌 순위를 이용하여 계산한다.
- ④ 상관관계가 없다는 것이 반드시 독립을 의미하지는 않는다.

35. 로지스틱 회귀분석(Logistic Regression) 모델의 가정 및 특징에 대한 설명으로 가장 옳지 않은 것을 고르세요.

- ① 독립변수들은 정규분포를 따라야 한다.
- ② 종속변수는 범주형 데이터(예: 0 또는 1)이다.
- ③ 다중공선성 문제를 해결하기 위해 독립변수 간 높은 상관관계는 확인해야 한다.
- ④ 종속변수의 예측 결과는 0과 1 사이의 확률값으로 출력된다.

36. 데이터 탐색 과정에서 변수의 분포나 특성을 하나의 값으로 요약하여 표현하는 '요약 변수(통계량)'에 대한 설명으로 가장 옳은 것을 고르세요.

- ① 중앙값은 데이터에 극단적인 이상치가 존재할 때 평균보다 대표값으로 더 적절할 수 있다.
- ② 분산은 데이터의 중심 경향을 나타내는 대표적인 지표이다.
- ③ 범위(Range)는 데이터의 모든 값을 고려하므로 가장 안정적인 산포도 지표이다.
- ④ 최빈값은 연속형 데이터에서만 사용할 수 있다.

37. 모델의 성능을 향상시키기 위한 변수 선택(Feature Selection) 방법에 대한 설명으로 가장 옳은 것을 고르세요.

- ① 변수의 개수가 많을수록 모델의 성능은 항상 향상된다.
- ② 전진 선택법(Forward Selection)은 모든 변수를 포함한 모델에서 시작하여 중요도가 낮은 변수를 하나씩 제거하는 방식이다.
- ③ 교차 검증(Cross-validation)은 변수 선택 과정에서 모델의 과적합을 방지하고 일반화 성능을 평가하는 데 사용될 수 있다.
- ④ 변수 선택은 훈련 데이터와 테스트 데이터를 모두 사용하여 수행해야 한다.

38. 데이터 정제(Data Cleansing) 활동에 대한 설명으로 가장 옳지 않은 것을 고르세요.

- ① 결측치가 발견되면 해당 데이터 행을 항상 즉시 제거해야 한다.
- ② 이상치(Outlier)는 통계 기법(예: IQR)을 통해 탐지할 수 있다.
- ③ 데이터의 일관성을 위해 측정 단위를 통일하는 작업(예: cm를 m로)을 수행할 수 있다.
- ④ 결측치는 다른 변수와의 관계를 고려하여 평균, 중앙값 또는 예측값 등으로 대체(imputation)할 수 있다.

39. 세 개 이상의 독립적인 표본 집단들 간의 평균에 통계적으로 유의미한 차이가 있는지를 검정하기 위해 사용되는 통계 분석 방법은 무엇인가?

- ① 독립표본 T-검정 (Independent T-test)
- ② 카이제곱 검정 (Chi-squared test)
- ③ 분산분석 (ANOVA)
- ④ 상관분석 (Correlation Analysis)

40. 두 확률변수 X와 Y의 관계에 대한 설명으로 항상 옳은 것을 고르세요.

- ① 두 변수의 공분산($Cov(X, Y)$)이 0이면, 두 변수는 서로 독립이다.
- ② 두 변수가 서로 독립이면, 두 변수의 공분산($Cov(X, Y)$)은 0이다.
- ③ 두 변수의 상관계수가 1이면, 두 변수는 완전히 동일한 변수이다.
- ④ 두 변수의 공분산 값은 항상 -1과 1 사이에 존재한다.

제 3과목 : 빅데이터 모델링

41. 계층적 군집 분석의 결과를 시각화한 덴드로그램(Dendrogram)에서, 특정 높이에서 수평으로 선을 그었을 때 해당 선이 2개의 수직선과 교차했다면, 이는 군집을 몇 개로 설정한 것을 의미하는가?

- ① 1개
- ② 2개
- ③ 3개
- ④ 4개

42. 시계열 데이터가 '비정상성(Non-stationarity)'을 갖는다는 것의 의미로 가장 적절한 것을 고르세요.

- ① 데이터의 평균과 분산이 시간에 따라 변한다.
- ② 데이터가 특정 주기를 가지고 반복적으로 나타난다.
- ③ 데이터 값들이 서로 독립적이다.
- ④ 데이터의 분포가 정규분포를 따른다.

43. 머신러닝 모델의 과적합(Overfitting)을 방지하거나 완화하기 위한 방법으로 가장 거리가 먼 것을 고르세요.

- ① 훈련 데이터의 양을 늘린다.
- ② 모델에 규제(Regularization)를 적용하여 복잡도를 낮춘다.
- ③ 드롭아웃(Dropout)을 사용하여 학습 시 일부 뉴런을 비활성화한다.
- ④ 은닉층의 활성화 함수로 ReLU를 사용하여 학습 속도를 높인다.

44. 앙상블(Ensemble) 학습 기법인 배깅(Bagging)과 부스팅(Boosting)에 대한 설명으로 가장 옳은 것을 고르세요.

- ① 배깅은 모델의 편향(Bias)을, 부스팅은 분산(Variance)을 줄이는 데 효과적이다.
- ② 배깅은 이전 모델의 오차를 보완하며 순차적으로 학습하고, 부스팅은 독립적으로 모델을 병렬 학습한다.
- ③ 배깅은 분산(Variance)을, 부스팅은 편향(Bias)을 줄이는 데 효과적이다.
- ④ 두 기법 모두 단일 모델보다 항상 우수한 성능을 보장한다.

45. 차원 축소 기법인 주성분 분석(PCA)에 대한 설명으로 가장 옳지 않은 것을 고르세요.

- ① 데이터 변동성이 가장 작은 방향으로 첫 번째 주성분(PC1)을 설정한다.
- ② 서로 상관관계가 있는 고차원 변수들을 선형 결합하여 새로운 저차원 변수(주성분)를 만든다.
- ③ 주성분들은 서로 직교(orthogonal)하며, 이는 서로 독립적임을 의미한다.
- ④ 다중공선성 문제를 해결하기 위한 방법으로도 사용될 수 있다.

46. 기업에서 새로운 분석 과제를 발굴하는 하향식 접근법(Top-down Approach)에 대한 설명으로 가장 적절한 것을 고르세요.

- ① 분석가가 데이터를 자유롭게 탐색하며 숨겨진 패턴이나 인사이트를 찾아내는 방식이다.
- ② 비즈니스 문제를 해결하기 위해 필요한 분석 목표를 먼저 정의하고, 이에 필요한 데이터를 찾아 분석하는 방식이다.
- ③ 특정 분석 기법이나 알고리즘을 먼저 정하고, 이를 적용해볼 만한 데이터를 찾아 문제를 정의하는 방식이다.
- ④ 현업 실무자의 경험이나 직관에서 출발하여 분석 아이디어를 상향식으로 제안하는 방식이다.

47. 머신러닝 모델의 파라미터(Parameter)와 하이퍼파라미터(Hyperparameter)에 대한 설명으로 가장 옳지 않은 것을 고르세요.

- ① 파라미터는 모델이 훈련 데이터를 통해 스스로 학습하여 찾아내는 값이다.
- ② 하이퍼파라미터는 모델 학습 전에 사용자가 직접 설정해주는 값이다.
- ③ 선형 회귀 모델의 회귀 계수는 파라미터에, 의사결정나무의 최대 깊이는 하이퍼파라미터에 해당한다.
- ④ 인공신경망의 가중치(weights)와 KNN의 k값은 모두 대표적인 하이퍼파라미터이다.

48. 의사결정나무(Decision Tree) 모델에 대한 설명으로 가장 잘못된 것을 고르세요.

- ① 분석 결과를 누구나 쉽게 이해할 수 있도록 시각적으로 표현할 수 있어 해석이 용이하다.
- ② 데이터의 스케일링(Scaling)과 같은 전처리 과정이 전혀 필요 없다.
- ③ 분류와 회귀 문제 모두에 적용할 수 있는 비모수적 모델이다.
- ④ 너무 깊게 성장할 경우 훈련 데이터에 과적합될 위험이 있다.

49. 다중 회귀 분석에서 발생하는 다중공선성(Multicollinearity) 문제에 대한 설명으로 가장 옳지 않은 것을 고르세요.

- ① 독립변수들 간에 강한 선형 상관관계가 존재할 때 발생한다.
- ② 다중공선성이 존재하면 회귀 계수의 분산이 커져 모델이 불안정해진다.
- ③ 분산 팽창 계수(VIF)를 통해 진단할 수 있으며, 보통 VIF 값이 10 이상이면 문제가 있다고 판단한다.
- ④ 다중공선성을 해결하기 위해 상관관계가 높은 독립변수들을 추가로 모델에 포함시켜야 한다.

50. 데이터가 정규분포를 따르는지를 검정하는 '정규성 검정' 방법에 해당하지 않는 것을 고르세요.

- ① Shapiro-Wilk test
- ② Kolmogorov-Smirnov test
- ③ Q-Q Plot
- ④ t-test

51. 앙상블 기법 중 하나인 부스팅(Boosting)에 대한 설명으로 가장 옳은 것을 고르세요.

- ① 여러 개의 약한 학습기(Weak Learner)를 순차적으로 학습시켜 결합한다.
- ② 훈련 데이터에서 중복을 허용하여 여러 개의 데이터셋을 만들고 병렬적으로 학습한다.
- ③ 각 모델의 예측 결과를 다수결 투표나 평균을 통해 최종 결과를 도출한다.
- ④ 모델의 분산(Variance)을 줄이는 데 가장 효과적인 방법이다.

52. 딥러닝에서 널리 사용되는 활성화 함수인 **ReLU(Rectified Linear Unit)**에 대한 설명으로 가장 옳은 것을 고르세요.

- ① 입력값이 음수이면 해당 값을 그대로 출력하고, 양수이면 0을 출력한다.
- ② 함수의 형태가 복잡하여 계산 비용이 많이 든다.
- ③ 입력값이 0보다 작을 때 기울기가 0이 되어 학습이 진행되지 않는 'Dying ReLU' 문제가 발생할 수 있다.
- ④ Sigmoid나 Tanh 함수와 마찬가지로 기울기 소실(Vanishing Gradient) 문제가 자주 발생한다.

53. 의사결정나무 모델에서 '가지치기(Pruning)'를 수행하는 주된 이유로 가장 적절한 것을 고르세요.

- ① 모델의 학습 속도를 높이기 위해
- ② 모델의 과적합(Overfitting)을 방지하기 위해
- ③ 불순도(Impurity)를 최대한 낮추기 위해
- ④ 더 많은 분류 규칙을 생성하기 위해

54. 두 변수 '나이'와 '최대 심박수'에 대한 산점도(Scatter plot)를 분석한 결과로 가장 가능성이 높은 것을 고르세요.

- ① 두 변수는 강한 양(+)의 상관관계를 가진다.
- ② 두 변수는 음(-)의 상관관계를 가진다.
- ③ 두 변수는 아무런 상관관계가 없다.
- ④ 두 변수의 상관계수는 1.5에 가까운 값을 가진다.

55. 서포트 벡터 머신(SVM)이 비선형(non-linear) 데이터 분류 문제를 해결하기 위해 사용하는 핵심적인 방법은 무엇인가?

- ① 데이터를 여러 개의 부분집합으로 나누어 독립적으로 분석한다.
- ② 입력 데이터를 더 높은 차원의 특징 공간으로 매핑(mapping)하여 선형 분리가 가능하도록 한다.
- ③ 각 데이터 포인트에 가중치를 부여하여 분류하기 어려운 데이터에 집중한다.
- ④ 다수결 투표를 통해 여러 개의 분류기 결과를 종합한다.

56. 순환 신경망(RNN) 기반 모델의 장기 의존성 문제를 해결하고, 번역이나 요약 과제에서 입력 시퀀스의 특정 부분에 집중하기 위해 등장한 '어텐션(Attention)' 메커니즘에 대한 설명으로 옳은 것을 모두 고른 것은?

가. 인코더의 모든 정보를 하나의 고정된 크기 벡터에 압축할 때 발생하는 정보 손실을 보완한다.
나. 디코더가 출력을 예측하는 매 시점(time step)마다 인코더의 전체 입력 시퀀스를 다시 참고한다.
다. RNN의 기울기 소실(Vanishing Gradient) 문제를 근본적으로 해결하는 기법이다.

- ① 가
- ② 가, 나
- ③ 나, 다
- ④ 가, 나, 다

57. 다음 중 다변량 분산분석(MANOVA)을 적용하기에 가장 적절한 데이터 구성은 무엇인가?

- ① 독립변수: 지역(A, B, C), 종속변수: 월 평균 소득
- ② 독립변수: 교육 수준, 종속변수: 직업 만족도, 스트레스 지수
- ③ 독립변수: 광고 채널(TV, 라디오, 신문), 종속변수: 매출액, 브랜드 인지도, 고객 만족도
- ④ 독립변수: 나이, 소득 수준, 종속변수: 제품 구매 여부

58. 성공 확률 p 를 입력받아 이를 $(-\infty, +\infty)$ 범위의 실수값으로 변환하는 함수로, 로지스틱 회귀분석의 핵심이 되는 변환은 무엇인가? (단, 변환 공식은 $\log(p/(1-p))$ 이다.)

- ① 시그모이드 변환 (Sigmoid Transformation)
- ② 로그 변환 (Log Transformation)
- ③ 로짓 변환 (Logit Transformation)
- ④ 소프트맥스 변환 (Softmax Transformation)

59. 시계열 예측 모델인 **ARIMA(p, d, q)**에 대한 설명으로 가장 옳지 않은 것을 고르세요.

- ① **AR(p)**는 자기회귀, **I(d)**는 차분, **MA(q)**는 이동평균 요소를 의미한다.
- ② **I(d)**의 차분 과정은 비정상성(non-stationary) 시계열을 정상성(stationary)으로 변환하기 위해 수행된다.
- ③ 비정상성 시계열 데이터는 **ARIMA** 모델로 분석할 수 없다.
- ④ 계절성(Seasonality) 패턴을 반영하기 위해 확장된 **SARIMA** 모델을 사용한다.

60. 연관규칙분석(**Association Rule Mining**)에서 규칙의 유용성을 평가하는 지표에 대한 설명으로 가장 옳지 않은 것을 고르세요.

- ① 지지도(Support)는 전체 거래 중 항목 A와 B가 동시에 포함된 거래의 비율이다.
- ② 신뢰도(Confidence)는 항목 A를 포함한 거래 중에서 항목 B도 함께 포함한 거래의 비율이다.
- ③ 향상도(Lift)가 1보다 크면, 항목 A와 B는 서로 양의 상관관계를 가진다고 해석할 수 있다.
- ④ 신뢰도가 높을수록 항상 유의미하고 흥미로운 규칙이라고 할 수 있다.

제 4과목 : 빅데이터 결과 해석

61. 이진 분류 모델의 예측 성능을 평가하는 혼동 행렬(**Confusion Matrix**)의 구성 요소가 아닌 것을 고르세요.

- ① TP (True Positive)
- ② FP (False Positive)
- ③ TN (True Negative)
- ④ VIF (Variance Inflation Factor)

62. 모델의 최적 하이퍼파라미터를 찾기 위한 '그리드 서치(**Grid Search**)'에 대한 설명으로 가장 옳은 것을 고르세요.

- ① 사용자가 지정한 하이퍼파라미터 값들의 모든 조합을 체계적으로 탐색한다.
- ② 탐색 공간에서 무작위로 하이퍼파라미터 조합을 선택하여 검증한다.
- ③ 베イズ 정리를 기반으로 이전 탐색 결과를 활용하여 다음 탐색 지점을 결정한다.
- ④ 항상 가장 짧은 시간 안에 최적의 하이퍼파라미터를 찾을 수 있다.

63. 학습 곡선(Learning Curve)을 분석한 결과, 훈련 데이터가 늘어남에 따라 훈련 오차와 검증 오차가 모두 높은 수준에서 더 이상 개선되지 않고 수렴하는 양상을 보였다. 이 현상이 의미하는 것으로 가장 적절한 것을 고르세요.

- ① 모델이 훈련 데이터에 과적합(Overfitting)되었다.
- ② 모델이 과소적합(Underfitting) 상태이며, 모델의 표현력이 부족하다.
- ③ 최적의 모델을 찾았으므로 더 이상의 개선은 불필요하다.
- ④ 훈련 데이터의 양이 너무 많아서 발생하는 문제이다.

64. 모델의 학습 과정에서 훈련 오차(Training Error)는 지속적으로 감소하지만, 검증 오차(Validation Error)는 특정 시점부터 다시 증가하는 현상이 나타났다. 이 현상을 가장 잘 설명하는 용어는 무엇인가?

- ① 과적합 (Overfitting)
- ② 과소적합 (Underfitting)
- ③ 일반화 (Generalization)
- ④ 수렴 (Convergence)

65. 최적화 기법인 경사 하강법(Gradient Descent)에 대한 설명으로 가장 옳지 않은 것을 고르세요.

- ① 손실 함수(Loss Function)의 기울기(gradient)를 이용하여 파라미터를 업데이트한다.
- ② 확률적 경사 하강법(SGD)은 전체 데이터가 아닌 미니배치를 사용하여 파라미터를 업데이트하므로 계산 효율이 높다.
- ③ 학습률(Learning Rate)이 너무 크면 최적점을 지나쳐 발산(diverge)할 수 있다.
- ④ 비볼록(non-convex) 함수에서도 항상 전역 최솟값(global minimum)을 찾는 것을 보장한다.

66. 딥러닝 모델의 하이퍼파라미터 및 구성 요소에 대한 설명으로 가장 틀린 것을 고르세요.

- ① 딥러닝 모델의 은닉층에 비선형 활성화 함수가 없으면, 여러 층을 쌓더라도 결국 하나의 선형 모델과 같다.
- ② 하이퍼파라미터는 모델이 학습을 통해 스스로 찾아내는 값이므로 사용자가 직접 설정할 수 없다.
- ③ 학습률(Learning Rate)은 경사 하강법에서 파라미터를 업데이트하는 보폭(step size)을 결정하는 중요한 하이퍼파라미터이다.
- ④ 드롭아웃(Dropout)은 학습 시 일부 뉴런을 무작위로 비활성화하여 과적합을 방지하는 규제 기법이다.

67. 이진 분류 모델의 성능을 평가하는 ROC 곡선(Receiver Operating Characteristic Curve)과 AUC(Area Under the Curve)에 대한 설명으로 가장 옳지 않은 것을 고르세요.

- ① ROC 곡선은 모든 분류 임계값(threshold)에 대해 모델의 성능 변화를 시각화한 것이다.
- ② x축은 FPR(False Positive Rate), y축은 TPR(True Positive Rate)로 구성된다.

- ③ AUC 값은 0.5에 가까울수록 모델의 성능이 우수함을 의미한다.
- ④ 클래스 분포가 불균일할 때도 모델의 성능을 객관적으로 평가할 수 있는 지표이다.

68. 데이터를 **K**개의 부분집합(폴드)으로 나누어, **K-1**개를 훈련 데이터로, **1**개를 검증 데이터로 사용하는 과정을 **K**번 반복하여 모델의 성능을 평가하는 방법은 무엇인가?

- ① 홀드아웃 검증 (Hold-out Validation)
- ② K-폴드 교차 검증 (K-Fold Cross-validation)
- ③ 리브원아웃 교차 검증 (LOOCV)
- ④ 부트스트래핑 (Bootstrapping)

69. 군집 분석(Clustering)의 성능을 평가하는 지표 중, 각 데이터 포인트가 속한 군집 내 다른 데이터들과 얼마나 가깝고, 다른 군집의 데이터들과는 얼마나 멀리 떨어져 있는지를 나타내는 지표는 무엇인가?

- ① 엔트로피 (Entropy)
- ② 지니 계수 (Gini Index)
- ③ 실루엣 계수 (Silhouette Coefficient)
- ④ R-제곱 (R-squared)

70. 암 환자를 예측하는 의료 진단 모델을 평가하고자 한다. 실제 암 환자를 놓치지 않고 최대한 많이 찾아내는 것이 중요할 때(즉, **FN**을 최소화해야 할 때), 가장 우선적으로 고려해야 할 평가지표는 무엇인가?

- ① 정확도 (Accuracy)
- ② 정밀도 (Precision)
- ③ 재현율 (Recall)
- ④ F1 점수 (F1 Score)

71. 데이터 시각화의 역할 및 기능에 대한 설명으로 가장 옳지 않은 것을 고르세요.

- ① 대량의 데이터 속에 숨어있는 패턴, 추세, 이상치 등을 쉽게 파악할 수 있도록 돕는다.
- ② 복잡한 분석 결과를 비전문가도 직관적으로 이해할 수 있도록 전달하는 데 효과적이다.
- ③ 시각화는 항상 객관적인 사실만을 전달하므로 해석의 왜곡이 발생할 가능성이 없다.
- ④ 탐색적 데이터 분석(EDA) 과정에서 데이터에 대한 이해를 높이는 데 중요한 역할을 한다.

72. 분류 모델의 평가지표인 **F1 Score**는 어떤 두 지표의 조화 평균(Harmonic Mean)으로 계산되는가?

- ① 정확도(Accuracy)와 재현율(Recall)
- ② 정밀도(Precision)와 특이도(Specificity)
- ③ 재현율(Recall)과 특이도(Specificity)
- ④ 정밀도(Precision)와 재현율(Recall)

73. 분류 모델의 성능 평가에서, 실제 '**참(Positive)**'인 데이터 중에서 모델이 '**참(Positive)**'으로 올바르게 예측한 데이터의 비율을 나타내는 지표는 무엇인가?

- ① 정확도 (Accuracy)
- ② 정밀도 (Precision)
- ③ 민감도 (Sensitivity)
- ④ 특이도 (Specificity)

74. 전체 데이터를 훈련 데이터(**Training set**)와 검증 데이터(**Validation set**)로 분리하여, 훈련 데이터로 모델을 학습시킨 후 검증 데이터로 성능을 평가하는 가장 기본적인 모델 검증 방법은 무엇인가?

- ① 홀드아웃 검증 (Hold-out Validation)
- ② K-폴드 교차 검증 (K-Fold Cross-validation)
- ③ 리브원아웃 교차 검증 (LOOCV)
- ④ 부트스트래핑 (Bootstrapping)

75. 모델이 훈련 데이터에 과도하게 학습되어 일반화 성능이 떨어지는 과적합(**Overfitting**) 현상에 대한 설명으로 가장 옳은 것을 고르세요.

- ① 데이터의 수가 많을수록 과적합이 발생하기 쉽다.
- ② 모델의 복잡도가 낮을수록(단순할수록) 과적합이 발생하기 쉽다.
- ③ 훈련 데이터의 양에 비해 모델의 복잡도가 너무 높을 때 발생하기 쉽다.
- ④ 과적합된 모델은 훈련 오차와 테스트 오차가 모두 높게 나타난다.

76. 직업 전환 여부를 예측하는 로지스틱 회귀분석 결과, '자격증 유무' 변수의 회귀 계수(coefficient)가 **-0.8**이고 **p-value**가 **0.01**로 나타났다. 이 결과에 대한 해석으로 가장 적절한 것을 고르세요. (단, 유의수준은 **0.05**이다.)

- ① 자격증 유무는 직업 전환에 아무런 영향을 주지 않는다.
- ② 자격증을 가진 사람은 자격증이 없는 사람보다 이직할 가능성이 낮다.
- ③ 자격증을 가진 사람은 자격증이 없는 사람보다 이직할 가능성이 높다.
- ④ p-value가 유의수준보다 크므로 이 결과는 통계적으로 의미가 없다.

77. Lasso(L1 규제) 회귀 모델이 변수 선택(feature selection) 효과를 가지며 '희소(sparse)'한 모델을 만드는 이유로 가장 적절한 것을 고르세요.

- ① 손실 함수에 추가되는 패널티 항이 회귀 계수의 제곱합 형태이기 때문이다.
- ② 손실 함수에 추가되는 패널티 항이 회귀 계수의 절댓값합 형태이기 때문이다.
- ③ 모든 독립변수들을 직교하는 주성분으로 변환하기 때문이다.
- ④ 의사결정나무 기반으로 중요도가 낮은 변수를 제거하기 때문이다.

78. 아래 보기 중 데이터의 품질(**Quality**)을 측정하고 관리하는 주요 차원으로만 묶인 것을 고르세요.

- 가. 완전성 (Completeness)
- 나. 유효성 (Validity)
- 다. 희소성 (Sparsity)
- 라. 일관성 (Consistency)

- ① 가, 나
- ② 가, 다, 라
- ③ 가, 나, 라
- ④ 가, 나, 다, 라

79. 인포그래픽(Infographic)에 대한 설명으로 가장 옳지 않은 것을 고르세요.

- ① 데이터, 정보, 지식을 시각적으로 표현하여 독자의 빠르고 쉬운 이해를 돕는다.
- ② 차트나 그래프 외에 아이콘, 이미지, 텍스트 등을 활용하여 특정 스토리를 전달한다.
- ③ 데이터 시각화와 완전히 동일한 개념으로, 어떤 데이터 시각화든 인포그래픽이라고 할 수 있다.
- ④ 정보 전달뿐만 아니라 설득, 마케팅, 교육 등 다양한 목적으로 활용될 수 있다.

80. 데이터 시각화 유형 중, 두 변수 간의 관계를 파악하는 '관계형 시각화'에 해당하지 않는 것을 고르세요.

- ① 산점도 (Scatter Plot)
- ② 버블 차트 (Bubble Chart)
- ③ 히트맵 (Heatmap)
- ④ 히스토그램 (Histogram)