

빅데이터분석기사 기출문제 해설집

1과목: 빅데이터의 이해

1. HDFS에 대한 설명으로 옳은 것은?

- ① 복제의 횟수는 내부에서 결정된다.
- ② ETL, NTFA가 상위 프로그램이다.
- ③ GFS와 동일한 소스코드를 사용한다.
- ④ 네임노드는 저장공간에 네임노드 데이터를 같이 저장한다.

정답: ③

해설: HDFS(Hadoop Distributed File System)는 Google의 GFS(Google File System) 논문을 기반으로 개발되어 동일한 소스코드를 사용합니다. 복제 횟수는 관리자가 설정할 수 있고, 네임노드는 메타데이터를 별도로 관리합니다.

2. 인공지능학습에 대한 설명으로 옳지 않은 것은?

- ① 훌륭한 알고리즘을 보유하였다면 학습을 생략해도 된다.
- ② 강인공지능은 범용으로 사용되기는 시기 상조이다.
- ③ 약인공지능의 제한된 기능을 뛰어넘어 더 발달된 인공지능이다.
- ④ 강인공지능이라고 불릴 만한 수준의 인공지능은 지금도 개발되지 않았다.

정답: ①

해설: 아무리 훌륭한 알고리즘이라도 데이터를 통한 학습 과정은 필수입니다. 학습을 통해 패턴을 찾고 모델을 최적화해야 합니다.

3. 분산파일 시스템에 대한 설명으로 옳은 것은?

- ① 데이터베이스를 분산 저장한다.
- ② x86 서버의 CPU, RAM 등을 사용하므로 장비 증가에 따른 성능향상에 용이하다.
- ③ 여러 컴퓨터를 하나의 서버 환경에 저장한다.
- ④ 네트워크를 통한 여러 파일을 관리 및 저장하는 개념이다.

정답: ④

해설: 분산파일시스템은 네트워크로 연결된 여러 컴퓨터에 파일을 분산 저장하고 관리하는 시스템입니다. 데이터베이스가 아닌 파일을 대상으로 합니다.

4. 분석로드맵 설정시 우선순위 고려해야할 사항 아닌 것은?

- ① 비즈니스 성관 및 ROI
- ② 시급성
- ③ 분석 데이터 적용
- ④ 전략적 중요도

정답: ③

해설: 분석로드맵 설정 시에는 비즈니스 성과, ROI, 시급성, 전략적 중요도를 고려하며, '분석 데이터 적용'은 우선순위 설정 기준이 아닙니다.

5. 분석 시나리오 적용을 해야 하는 이유로 가장 적절하지 않은 것은?

- ① 이해관계자 도출
- ② 업무성과 판단
- ③ 최신 업무 형태 반영
- ④ 분석 목표 도출

정답: ③

해설: 분석 시나리오는 이해관계자 도출, 업무성과 판단, 분석 목표 도출을 위해 적용하며, 최신 업무 형태 반영은 직접적인 목적이 아닙니다.

6. 빅데이터 분석기획 절차는?

- ① 프로젝트정의 → 범위설정 → 위험계획수립 → 수행계획수립
- ② 프로젝트정의 → 범위설정 → 수행계획수립 → 위험계획수립
- ③ 범위설정 → 프로젝트정의 → 수행계획수립 → 위험계획수립
- ④ 범위설정 → 프로젝트정의 → 위험계획수립 → 수행계획수립

정답: ③

해설: 빅데이터 분석기획은 먼저 범위를 설정하고, 프로젝트를 정의한 후, 수행계획을 수립하고 마지막에 위험계획을 수립하는 순서입니다.

7. 개인정보 비동의 시에도 사용 가능한 경우가 아닌 것은?

- ① 법령상 의무를 준수하기 위하여 불가피한 경우
- ② 계약의 체결 및 이행을 위하여 불가피하게 필요한 경우
- ③ 정보주체 또는 제3자의 급박한 생명, 신체, 재산의 이익을 위하여 필요하다고 인정되는 경우
- ④ 개인 편의 제공 시 합당한 이유가 있으면 가능하다.

정답: ④

해설: 개인정보보호법상 비동의 시에도 사용 가능한 경우는 법령상 의무, 계약 이행, 급박한 위험 상황 등으로 제한되며, 단순한 편의 제공은 해당되지 않습니다.

8. 개인정보 비식별화 기술에 대한 설명 중 가장 적절하지 않은 것은?

- ① 총계처리: 데이터의 총합 값으로 처리하여 개인 데이터의 값을 보이지 않도록 하는 기술
- ② 데이터 마스킹 : 개인식별에중요한 데이터 값을 삭제하는 기술
- ③ 가명처리: 개인 식별에 중요한 데이터를 식별할수 없는 다른 값으로 변경하는 기술
- ④ 범주화: 데이터의 값을 범주의 값으로 변환하여 값을 변경하는 기술

정답: ②

해설: 데이터 마스킹은 삭제가 아닌 특정 문자(*, #)로 치환하거나 일부를 가리는 기술입니다.

9. 가트너가 정의한 빅데이터 처리 플랫폼 특징 중 3V에 속하지 않는 것은?

- ① Value
- ② Volume
- ③ Velocity
- ④ Variety

정답: ①

해설: 가트너의 빅데이터 3V는 Volume(크기), Velocity(속도), Variety(다양성)입니다. Value(가치)는 나중에 추가된 4V의 요소입니다.

10. 1제타바이트에 1byte의 아스키 코드를 넣으면 얼마나 넣을 수 있는가?

- ① 2의 40승
- ② 2의 50승
- ③ 2의 60승
- ④ 2의 70승

정답: ④

해설: 1 제타바이트 = 2^{70} 바이트이므로, 1byte씩 넣을 수 있는 개수는 2^{70} 개입니다.

11. 다음 중 인메모리기반의 데이터 처리와 연관된 오픈소스 프로젝트는?

- ① 스파크
- ② 맵리듀스
- ③ 하이브
- ④ 피그

정답: ①

해설: Apache Spark는 인메모리 기반의 빠른 데이터 처리를 제공하는 오픈소스 프로젝트입니다. 맵리듀스는 디스크 기반 처리입니다.

12. 다음 중 데이터분석 모델링과 관련하여 수행하는 업무가 아닌 것은?

- ① 데이터 분할
- ② 데이터 모델링
- ③ 프로젝트 성과 분석 및 평가 보고
- ④ 모델 적용 및 운영방안

정답: ③

해설: 프로젝트 성과 분석 및 평가 보고는 모델링 완료 후의 업무로, 모델링 단계의 업무가 아닙니다.

13. 다음 중 정형데이터와 비정형데이터와 관련된 것 중 옳은 것은?

- ① 동영상, 오디오 데이터는 정형 데이터에 속한다.
- ② 형태소는 정형데이터를 분석하기 위한 단위이다.
- ③ 정형데이터는 지정된 행과열에 의해 데이터의 속성이 구별되는 스프레드시트 형태의 데이터이다.
- ④ 비정형 데이터는 잠재적 가치가 가장 낮다.

정답: ③

해설: 정형데이터는 행과 열로 구성된 표 형태의 구조화된 데이터입니다. 동영상/오디오는 비정형, 형태소는 비정형 텍스트 분석 단위입니다.

14. 다음 중 고품질데이터의 특성이 아닌 것은?

- ① 정확성(Accuracy)
- ② 적시성(Timeliness)
- ③ 불편의성(Uncompleteness)
- ④ 일관성(Consistency)

정답: ③

해설: 고품질 데이터의 특성은 정확성, 적시성, 일관성, 완전성(Completeness) 등이며, 불편의성은 해당되지 않습니다.

15. 다음 중 시스템의전방에 위치하여 클라이언트로부터 다양한 서비스를 처리하고, 내부 시스템으로 전달하는 미들웨어는?

- ① API 게이트웨이
- ② 데이터베이스
- ③ Paas
- ④ ESB(Enterprise Service Bus)

정답: ①

해설: API 게이트웨이는 클라이언트 요청을 받아 적절한 백엔드 서비스로 라우팅하는 미들웨어 역할을 합니다.

16. 데이터 3법에 포함되는 것이 아닌 것은?

- ① 개인정보보호법
- ② 정보통신산업 진흥법
- ③ 정보통신망 이용촉진 및 정보보호 등에 관한 법률
- ④ 신용정보의 이용 및 보호에 관한 법률

정답: ②

해설: 데이터 3법은 개인정보보호법, 정보통신망법, 신용정보법으로 구성됩니다.

17. 공공데이터에서 제공하는 파일의 형식이 아닌 것은?

- ① xml
- ② Sql
- ③ Json
- ④ Csv

정답: ②

해설: 공공데이터는 주로 XML, JSON, CSV 형태로 제공되며, SQL은 데이터베이스 질의 언어로 파일 형식이 아닙니다.

18. 데이터 저장소가 아닌 것은?

- ① 데이터 웨어하우스
- ② 데이터 레이크
- ③ 데이터 마이닝
- ④ 데이터 댐

정답: ③

해설: 데이터 마이닝은 데이터 분석 기법이지 저장소가 아닙니다. 나머지는 모두 데이터 저장소입니다.

19. 데이터에 노이즈를 추가해 개인정보와 데이터분석을 모두 진행할 수 있는 방법은?

- ① K익명성
- ② 가명화
- ③ 개인정보차등보호
- ④ L다양성

정답: ③

해설: 차등프라이버시(Differential Privacy)는 데이터에 노이즈를 추가하여 개인정보를 보호하면서 통계적 분석을 가능하게 하는 기법입니다.

20. 빅데이터 저장기술 중 옳은 것은?

- ① 맵리듀스
- ② 직렬화
- ③ 가시화
- ④ Nosql

정답: ④

해설: NoSQL은 빅데이터 저장을 위한 비관계형 데이터베이스 기술입니다. 맵리듀스는 처리 기술, 직렬화는 데이터 변환 기술, 가시화는 시각화 기술입니다.

2과목: 빅데이터 탐색

21. 다음 중 대표값관련 설명으로 옳지 않은 것은

- ① 평균은 중앙값보다 이상값에 영향을 더 적게 받는다.
- ② Q3-Q1같은 사분위수 범위를 의미한다.
- ③ 변동률 등은 기하 평균으로 구한다.
- ④ 변동계수는 분산과 관련이 있다.

정답: ①

해설: 평균은 중앙값보다 이상값(outlier)에 더 민감합니다. 중앙값이 이상값에 더 강건(robust)한 통계량입니다.

22. 사람의 평균수명 검정 문제

표본 100명, 표본평균 72.4년, 모표준편차 12년, 평균수명이 70년보다 긴지 검정($\alpha=0.05$)

- ① 표준정규확률변수 $z=2$, 귀무가설 채택
- ② 표준정규확률변수 $z=2$, 귀무가설 기각
- ③ 표준정규확률변수 $z=3$, 귀무가설 채택
- ④ 표준정규확률변수 $z=3$, 귀무가설 기각

정답: ②

해설: $z = (72.4-70)/(12/\sqrt{100}) = 2.4/1.2 = 2$. 임계값 1.645보다 크므로 귀무가설을 기각합니다.

23. 다음 중 시공간데이터가 아닌 것은?

- ① 지도 데이터
- ② 패턴 데이터
- ③ 패널 데이터
- ④ 격자 데이터

정답: ②

해설: 시공간 데이터는 시간과 공간 정보를 모두 포함하는 데이터로, 지도 데이터, 패널 데이터, 격자 데이터가 해당됩니다.

24. 다음 중 이상값을 찾는 방법에 대한 설명이 아닌 것은?

- ① 박스플롯과 스캐터 플롯 등에서 멀리 떨어진 값
- ② 정규분포에서 표준편차가 3이상인 값
- ③ 도메인 지식에서 이론적이나 물리적으로 맞지 않는 값
- ④ 가설 검정의 노이즈 값

정답: ④

해설: 이상값 탐지 방법으로는 시각적 방법, 통계적 방법(3σ 규칙), 도메인 지식 활용이 있으며, 가설 검정의 노이즈는 직접적인 이상값 탐지 방법이 아닙니다.

25. 다음 중 주성분분석에 대한 설명으로 틀린 것은?

- ① 선형 결합하여 새로운 변수를 만든다.
- ② 분산이 커지도록 한다.
- ③ 데이터가 이산적인 경우에 사용한다.
- ④ 직관적으로 이해할 수 있다.

정답: ④

해설: 주성분분석은 차원축소 기법으로 원래 변수들의 선형결합으로 새로운 변수를 만들지만, 새로운 변수의 의미를 직관적으로 해석하기 어렵습니다.

26. 상관관계에 대한 설명 중 틀린 것은?

- ① 상관계수는 결정계수의 제곱이다.
- ② 범위는 -1에서 1사이 이다.
- ③ 0에 가까우면 상관성이 낮다.
- ④ 관계를 산점으로 알 수 있다.

정답: ①

해설: 결정계수(R^2)가 상관계수(r)의 제곱입니다. 즉, $R^2 = r^2$ 입니다.

27. 정규 모집단 $N(50, 2^2)$ 에서 크기 $n=16$ 의 표본을 무작위 추출할때 표본평균 분포의 표준편차 또한 표본평균이 51이상일때의 표준화 점수, 이에 대한 분포는?

- ① $\sigma_x = 1/2, z=2, N(0,1)$
- ② $\sigma_x = 1, z=2, N(50, 2^2)$
- ③ $\sigma_x = 1/2, z=2, N(50, 2^2)$
- ④ $\sigma_x = 1, z=2, N(0,1)$

정답: ①

해설: 표본평균의 표준오차 $\sigma_x = \sigma/\sqrt{n} = 2/\sqrt{16} = 1/2$. $z = (51-50)/(1/2) = 2$. 표준화된 분포는 $N(0,1)$ 입니다.

28. 박스 플롯에서 3Q보다 작은 것은?

- ① 중앙값
- ② 평균
- ③ 80퍼센트
- ④ Max값

정답: ①

해설: 박스플롯에서 3사분위수(Q_3)는 75백분위수이므로, 중앙값(Q_2 , 50백분위수)이 Q_3 보다 작습니다.

29. 자료의 분포가 오른쪽으로 긴꼬리일 경우에 대한 설명으로 맞는 것은?

- ① 왜도 > 0, 빈도수 < 중위수 < 평균
- ② 왜도 > 0, 평균 < 중앙값 < 최빈값
- ③ 왜도 < 0, 중앙값 < 최빈값 < 평균
- ④ 왜도 < 0, 최빈값 < 중앙값 < 평균

정답: ①

해설: 오른쪽 꼬리 분포(우편향)는 왜도가 양수이며, 최빈값 < 중앙값 < 평균 순서입니다. (빈도수는 최빈값의 오타로 추정)

30. 이산 확률 변수 X 에 대해 $E(X) = 4$, $E(X^2) = 25$ 일 때, 확률 변수 $Y = 3X - 4$ 의 평균과 분산으로 옳은 것은?

- ① $E(Y) = 8$, $V(Y) = 81$
- ② $E(Y) = 16$, $V(Y) = 9$
- ③ $E(Y) = 8$, $V(Y) = 25$
- ④ $E(Y) = 16$, $V(Y) = 81$

정답: ①

해설:

- $V(X) = E(X^2) - [E(X)]^2 = 25 - 16 = 9$
 - $E(Y) = E(3X-4) = 3E(X) - 4 = 3 \times 4 - 4 = 8$
 - $V(Y) = V(3X-4) = 9V(X) = 9 \times 9 = 81$
-

31. 정규화에 대한 설명으로 옳은 것은?

- ① Min-max 정규화 범위는 0과 1 사이 이다.
- ② 평균은 0, 표준편차는 1로 변환 하는 방법 이다.
- ③ 정규화를 표준화하면 표준정규분포다
- ④ Minmax 정규화보다 z값이 이상치에 영향을 덜 받는다.

정답: ①

해설: Min-max 정규화는 데이터를 최솟값 0, 최댓값 1 범위로 변환합니다. ②는 표준화(Z-score)에 대한 설명입니다.

32. 정규 분포의 설명이 아닌 것은?

- ① 왜도가 3, 첨도가 0이다.
- ② 직선 $x=\mu$ (평균)에 대해 대칭인 종 모양의 곡선이다.
- ③ 곡선과 x축으로 둘러싸인 영역의 넓이는 1이다.
- ④ 곡선의 모양은 표준편차가 일정할 때, 평균이 변하면 대칭축의 위치와 곡선의 모양이 바뀐다.

정답: ①

해설: 정규분포의 왜도는 0, 첨도는 3입니다. (초과첨도는 0)

33. 포아송 분포 적합도 검정에 대한 설명

- ㄱ. 하루에 몇회인지 평균을 구해야한다.
- ㄴ. 카이제곱 값이 클수록 귀무가설 기각
- ㄷ. 자유도 4

- ① ㄱ, ㄴ
- ② ㄱ, ㄷ
- ③ ㄴ, ㄷ
- ④ ㄱ, ㄴ, ㄷ

정답: ①

해설: 포아송 분포 적합도 검정에서는 평균을 구해야 하고, 카이제곱 값이 클수록 귀무가설을 기각합니다. 자유도는 범주 수에서 추정된 모수 개수를 뺀 값입니다.

34. 각각의 사례에 알맞은 분석 방법으로 옳은 것은?

- ① 어떤 규칙이나 방법을 찾는데 회귀분석이나 군집분석을 사용한다.
- ② 수요예측은 회귀분석 등 연속형 모델 등을 이용하여 분석할 수 있고 인공지능망을 사용할 수도 있다.
- ③ 일정한 단위 시간의 변화에 따른 개개의 상품이나상품의 집합체에 관한 경제변량의 기본적인 관계를 나타내는 계수를 추정 및 분석하는 방법은 차원축소 분석을 사용한다.
- ④ 동일한 공간상에 비교한 상표들의 상대적 위치를 나타내는 분석방법은 요인분석이다.

정답: ②

해설: 수요예측은 회귀분석이나 시계열 분석, 인공지능망 등 다양한 방법을 사용할 수 있습니다. ④는 다차원척도법에 대한 설명입니다.

35. 비정형 텍스트 데이터 전처리 기법이 아닌 것은?

- ① Tokenizing
- ② API 이용
- ③ POS tagging
- ④ Stemming

정답: ②

해설: Tokenizing(토큰화), POS tagging(품사태깅), Stemming(어간추출)은 모두 텍스트 전처리 기법이며, API 이용은 전처리 기법이 아닙니다.

36. 빅데이터 탐색에 대한 설명으로 적절하지 않은 것은?

- ① 빅데이터의 전체 분포를 검토하는 과정이다.
- ② 데이터 분석과정에서 결과를 도출한다.
- ③ 데이터 탐색 시 잠재적 문제를 발견하는 과정이다.
- ④ 데이터 탐색 시 패턴을 찾는 과정이다.

정답: ②

해설: 빅데이터 탐색은 분석 전 단계로 데이터의 특성을 파악하는 과정이며, 최종 결과 도출은 분석 단계에서 이루어집니다.

37. 표준화와 점수분포에 관한 설명으로 적절한 것은?

- ① 표준화는 각 요소에서 평균을 뺀 값을 분산으로 나눈다.
- ② 표준화의 최대값은 1이다.
- ③ 표준화의 표준편차는 0이다.
- ④ 정규분포를 표준화하면 표준정규분포가 된다.

정답: ④

해설: 표준화는 $(X-\mu)/\sigma$ 로 계산하며, 정규분포를 표준화하면 $N(0,1)$ 인 표준정규분포가 됩니다. ①은 표준편차로 나누는 것이 맞습니다.

38. 소수의 극단값의 영향을 받지 않으므로 변동성 척도로서 적절한 것은?

- ① 범위
- ② 변동계수
- ③ 사분위범위
- ④ 표준편차

정답: ③

해설: 사분위범위(IQR = $Q3-Q1$)는 극단값에 강건한 변동성 척도입니다. 범위와 표준편차는 극단값에 민감합니다.

39. 초기하 분포의 설명으로 적절하지 않은 것은?

- ① 확률변수 값으로서 일정횟수의 베르누이 시행에서 성공횟수를 가진다.
- ② 성공확률은 일정하지 않다.
- ③ 각 시행은 독립적이다.
- ④ 이산형 확률분포를 따른다.

정답: ③

해설: 초기하분포는 복원하지 않고 추출하므로 각 시행이 독립적이지 않습니다. 성공확률도 시행마다 변합니다.

40. 박스플롯에 대한 설명으로 적절하지 않은 것은?

- ① 토요일의 분산은 금요일보다 크다.
- ② 금요일의 평균은 10에 가깝다.
- ③ 목요일의 1사분위수는 12에 가깝다.
- ④ 금요일에 이상값이 존재한다.

정답: ②

해설: 박스플롯에서는 평균을 직접 확인할 수 없으며, 중앙값만 확인 가능합니다.

3과목: 빅데이터 모델링

41. 텍스트 문맥 파악을 위해서 단어 단위로 끊어서 판별하는 기법은?

- ① 토픽 모델링
- ② 워드 클라우드
- ③ N-Gram
- ④ TFIDF

정답: ③

해설: N-Gram은 연속된 N개의 단어나 문자로 텍스트를 분할하여 문맥을 파악하는 기법입니다.

42. 선형회귀분석 오차항의 특성이 아닌 것은?

- ① 선형성
- ② 독립성
- ③ 정규성
- ④ 등분산성

정답: ①

해설: 선형회귀분석의 오차항 가정은 독립성, 정규성, 등분산성, 평균이 0입니다. 선형성은 회귀식의 특성이지 오차항의 특성이 아닙니다.

43. 비지도학습에 대한 설명으로 다음 빈칸에 들어갈 말로 알맞은 것은?

정답을 (), ()이 이에 속한다.

- ① 가르쳐주지 않고, 회귀분석
- ② 가르쳐주고, 회귀분석
- ③ 가르쳐주지 않고, 군집분석
- ④ 가르쳐주고, 군집분석

정답: ③ 가르쳐주지 않고, 군집분석

해설: 비지도학습은 정답(레이블)을 가르쳐주지 않고 학습하는 방법으로, 군집분석이 대표적인 예입니다.

44. 인공지능에 대한 설명으로 가장 거리가 먼 것은?

- ① 모델 예측값과 실제값의 오차인 비용함수(Cost Function)는 인공지능 학습에서 최적화된 비용에 관련된 모든 변량에 대하여 어떤 관계를 나타내는 함수이다.
- ② 일반적으로 여러개의 은닉층을 가진 신경망을 통해 데이터를 학습 하는 것을 딥러닝이라 한다.
- ③ 딥러닝은 인공신경망으로 발전했다.
- ④ 인공지능이 기율기 소실 문제로 인해 암흑기가 발생한 적이 있다.

정답: ③ 딥러닝은 인공신경망으로 발전했다.

해설: 딥러닝은 인공신경망에서 발전한 것이지, 딥러닝이 인공신경망으로 발전한 것이 아닙니다.

45. 인공신경망의 단층퍼셉트론 문제로 표현이 불가능한 논리회로는?

- ① AND
- ② OR
- ③ NOR
- ④ XOR

정답: ④ XOR

해설: 단층퍼셉트론은 선형분리 가능한 문제만 해결할 수 있으며, XOR 문제는 선형분리가 불가능해 다층퍼셉트론이 필요합니다.

46. 오토인코더에 대한 설명으로 가장 잘못된 것은?

- ① 비지도 학습이다.
- ② 사전학습으로 사용된다.
- ③ 입력수는 은닉층 수보다 항상 작다.
- ④ 인코더 입력수와 디코더 출력수는 동일하다.

정답: ③ 입력수는 은닉층 수보다 항상 작다.

해설: 오토인코더에서 은닉층의 노드 수는 입력층보다 작을 수도 클 수도 있으며, 항상 작다는 것은 잘못된 설명입니다.

47. Boolean Function 나이브 베이즈 함수로 잘못된 것은?

- ① $P(A,B|C) = P(A) \times P(B|C)$
- ② $P(A,B,C|E) = P(A|E) \times P(B|E) \times P(C|E)$
- ③ $P(A,B|C) = P(A|C) \times P(B|C)$
- ④ $P(A,E|C) = P(A|C) \times P(E|C)$

정답: ① $P(A,B|C) = P(A) \times P(B|C)$

해설: 나이브 베이즈에서 조건부 독립성을 가정할 때, $P(A,B|C) = P(A|C) \times P(B|C)$ 가 맞습니다.

48. 의사결정나무에 대한 설명 중 틀린 것은?

- ① 가지에 하나가 남는 끝까지 진행한다.
- ② 변수를 하나 골라서 한계치 설정한다.
- ③ 나무구조에 의해 모델이 표현되기 때문에 해석이 용이한 편이다.
- ④ 분류 및 예측 목적으로 사용할 수 있다.

정답: ① 가지에 하나가 남는 끝까지 진행한다.

해설: 의사결정나무는 과적합 방지를 위해 적절한 중단 규칙(stopping criteria)을 사용하며, 하나가 남을 때까지 무조건 진행하지 않습니다.

49. 범주형에 대한 분류방법이 아닌 것은?

- ① 인공신경망
- ② 선형회귀분석
- ③ 서포트 벡터머신
- ④ 의사결정나무

정답: ② 선형회귀분석

해설: 선형회귀분석은 연속형 종속변수를 예측하는 방법이며, 범주형 분류에는 사용하지 않습니다.

50. 다음이 설명하는 시계열의 특성은 무엇인가? (중장기적, 빈번한 발생 빈도가 없는 패턴)

- ① 추세
- ② 주기
- ③ 계절
- ④ 불규칙

정답: ② 주기

해설: 주기성(cycle)은 중장기적이고 불규칙한 간격으로 나타나는 패턴을 의미합니다. 계절성은 규칙적인 간격으로 반복됩니다.

51. 연관분석기법으로 알맞은 것은?

- ① 회귀분석
- ② Apriori
- ③ 군집분석
- ④ 월콕슨순위합

정답: ② Apriori

해설: Apriori 알고리즘은 연관규칙 마이닝의 대표적인 기법입니다.

52. 로지스틱 회귀분석에 대한 설명으로 잘못된 것은?

- ① 분류에 주로 사용한다.
- ② 자료형이 범주형을 갖는 경우 사용하는 분석기법이다.
- ③ Y값은 0과 1사이이다.
- ④ 대표적인 비지도 학습 알고리즘이다.

정답: ④ 대표적인 비지도 학습 알고리즘이다.

해설: 로지스틱 회귀분석은 지도학습 알고리즘입니다. 종속변수(레이블)가 있어야 학습이 가능합니다.

53. 비지도 학습 알고리즘 유형으로 알맞은 것은?

- ① 회귀분석
- ② 로지스틱 회귀분석
- ③ 서포트 벡터

④ 군집분석

정답: ④ 군집분석

해설: 군집분석은 레이블 없이 데이터의 유사성을 기반으로 그룹을 만드는 비지도학습 방법입니다.

54. 정준연결(Canonical link)의 로그함수로 알맞은 것은?

- ① 정규분포
- ② 베르누이
- ③ 포아송
- ④ 감마

정답: ③ 포아송

해설: 포아송 분포의 정준연결함수는 로그함수입니다. GLM에서 각 분포별로 고유한 정준연결함수를 가집니다.

55. 통계에서 평균에 대한 차이검정으로 모집단 3개 이상 사용하는 분석방법으로 가장 알맞은 것은?

- ① t검정
- ② z검정
- ③ 분산분석
- ④ 상관분석

정답: ③ 분산분석

해설: 분산분석(ANOVA)은 3개 이상의 집단 평균을 동시에 비교하는 방법입니다. t검정은 2개 집단 비교에 사용됩니다.

56. 비모수 통계 분석기법인 Wilcoxon Signed rank와 Wilcoxon rank sum 설명 중 가장 옳지 않은 것은?

- ① 윌콕슨 부호순위는 일변량 검정이다.
- ② 윌콕슨 순위합은 이변량 검정이다.
- ③ 주로 30개 이하의 작은 샘플일때 사용한다.
- ④ 윌콕슨 부호 순위 검정은 검정 결과가 대칭되어야 검정 가능하다.

정답: ④ 윌콕슨 부호 순위 검정은 검정 결과가 대칭되어야 검정 가능하다.

해설: 윌콕슨 부호순위 검정에서는 차이값의 분포가 대칭이어야 하며, 검정 결과가 대칭이어야 한다는 조건은 없습니다.

57. 아래의 수식이 나타내는 회귀는?

- ① 라쏘
- ② 릿지
- ③ 엘라스틱넷 회귀
- ④ 단순 회귀

정답: ② 릿지

해설: 릿지 회귀는 L2 정규화를 사용하여 회귀계수의 제곱합에 페널티를 부과하는 방법입니다.

58. 다음 설명 중 배깅에 대한 내용으로 가장 옳은 것은?

- ① 편향이 낮은 과소적합 모델을 사용한다.
- ② 편향이 높은 과대적합 모델을 사용한다.
- ③ 부트스트랩 자료를 생성하고 각 부트스트랩 자료를 결합하여 최종 예측모형 산출
- ④ 가중치를 활용하여 약 분류기를 강 분류기로 만드는방법

정답: ③ 부트스트랩 자료를 생성하고 각 부트스트랩 자료를 결합하여 최종 예측모형 산출

해설: 배깅(Bagging)은 Bootstrap Aggregating의 줄임말로, 부트스트랩 샘플링으로 여러 모델을 학습시켜 결합하는 앙상블 기법입니다.

59. 하이퍼파라미터의 최적화로 옳지 않은 것은?

- ① 랜덤 서치
- ② 그리드 서치
- ③ 베이지안 최적화
- ④ 경사하강법

정답: ④ 경사하강법

해설: 경사하강법은 모델 파라미터 최적화에 사용되며, 하이퍼파라미터 최적화 방법이 아닙니다.

60. 맨하탄 거리를 계산하시오 점A에서 2번째로 가까운 점의 거리는?

4개의 보기 A(1,1), B(1,2), C(2,2), D(4,1)

- ① 1
- ② 2
- ③ 3
- ④ 4

정답: ② 2

해설:

- A에서 B까지: $|1-1| + |1-2| = 1$

- A에서 C까지: $|1-2| + |1-2| = 2$

- A에서 D까지: $|1-4| + |1-1| = 3$

가장 가까운 점은 B(거리=1), 두 번째로 가까운 점은 C(거리=2)입니다.

4과목: 빅데이터 결과 해석

61. 시공간 시각화 기법 중 옳은 것은?

- ① 히스토그램
- ② 체르노프 페이스
- ③ 지도맵핑
- ④ 평행 좌표계

정답: ③ 지도맵핑

해설: 지도맵핑은 지리적 위치와 시간 정보를 함께 표현하는 시공간 시각화 기법입니다.

62. 실루엣 계수를 이용한 최적의 군집분석 갯수는?

- ① 2
- ② 3
- ③ 4
- ④ 5

정답: ② 3

해설: 실루엣 계수가 가장 높은 지점이 최적의 군집 수입니다. (그래프 분석 필요)

63. 다음 그래프의 이름으로 적절한 것은?

- ① 히트맵
- ② 트리맵
- ③ 영역차트
- ④ 누적영역차트

정답: ① 히트맵

해설: 히트맵은 데이터 값을 색상으로 표현하는 시각화 방법입니다.

64. 효과적인 인포그래픽의 조건 중 가장 적절하지 않은 것은?

- ① 인포메이션(Information)과 시각적 그래프의 합성어이다.
- ② 최대한 많은 정보를 담는다.
- ③ 쉽게 이해할 수 있도록 그래픽과 텍스트를 조합해 사용한다.
- ④ 누적영역차트

정답: ② 최대한 많은 정보를 담는다.

해설: 효과적인 인포그래픽은 핵심 정보를 간결하고 명확하게 전달하는 것이 중요하며, 너무 많은 정보는 오히려 가독성을 해칩니다.

65. $y=0$ 혹은 $y=1$ 값을 가지는 이진 분류 분석에서 $y=1$ 의 값이 $y=0$ 값의 2배일 때, 민감도, 특이도, 정확도에 대한 설명으로 적절한 것은?

- ① 민감도와 특이도 둘다 1일때 정확도는 1이다.
- ② 특이도가 1일 때 정확도는 $1/2$ 이다.
- ③ 민감도가 $1/2$ 일 때 정확도는 $1/2$ 이다.
- ④ 민감도와 특이도가 같을 때 정확도도 특이도와 같다.

정답: ① 민감도와 특이도 둘다 1일때 정확도는 1이다.

해설: 민감도와 특이도가 모두 1이면 모든 예측이 정확하므로 정확도도 1입니다.

66. 홀드아웃 관련 데이터가 아닌 것은?

- ① 검증데이터
- ② 학습데이터
- ③ 평가데이터
- ④ 증강데이터

정답: ④ 증강데이터

해설: 홀드아웃 방법은 데이터를 학습용, 검증용, 평가용으로 나누는 방법이며, 증강데이터는 홀드아웃과 직접적인 관련이 없습니다.

67. ROC 그래프의 설명으로 적절하지 않은 것은?

- ① 민감도가 1, 특이도가 0인 점을 지난다.
- ② 민감도가 0, 특이도가 1인 점을 지난다.
- ③ 가장 이상적인 그래프는 민감도가 1, 특이도가 1인 점을 지난다.
- ④ 특이도가 증가하는 그래프이다.

정답: ④ 특이도가 증가하는 그래프이다.

해설: ROC 곡선의 x축은 1-특이도(위양성률)이므로, x축이 증가할수록 특이도는 감소합니다.

68. A상품에 대한 인지도 조사결과

|구분|알고있음|모름|합계|

|---|---|---|---|

|아이가 있는 남자(명)|460|40|500|

|아이가 없는 남자(명)|440|60|500|

|합계|900|100|1000|

- ① A제품을 알고있을 확률은 0.90이다.
- ② 아이가 있는 남자이면서 A제품을 모르고 있을 확률은 0.04이다.
- ③ 아이가 없는 남자이면서 A제품을 모르고 있을 확률은 0.06이다.
- ④ 아이가 있는 남자 중에서 A제품을 알고 있을 확률은 약 0.92이다.

정답: ①, ④ (중복 정답)

해설:

- ① $900/1000 = 0.90$ (맞음)
 - ② $40/1000 = 0.04$ (맞음, 그러나 문제에서는 틀렸다고 표시)
 - ③ $60/1000 = 0.06$ (맞음, 그러나 문제에서는 틀렸다고 표시)
 - ④ $460/500 = 0.92$ (맞음)
-

69. 다음 관측값에 대한 설명으로 옳지 않은 것은?

54, 46, 60, 40

- ① 기대빈도 50
- ② 비율이 $p_1 = p_2 = p_3 = p_4 = 1/4$
- ③ 카이제곱 값이 4.64
- ④ 카이제곱(3) = 7.8이라면, 귀무가설을 기각한다.

정답: ④ 카이제곱(3) = 7.8이라면, 귀무가설을 기각한다.

해설: 계산된 카이제곱 값 4.64가 임계값 7.8보다 작으므로 귀무가설을 채택합니다.

70. 포아송 분포가 맞는지 적합도 검정을 한다면 보기중 가장 알맞은 것은?

- ① 연속형 확률 분포에서 주로 사용한다.
- ② 유의 수준은 사용하지 않는다.
- ③ P-value가 유의수준보다 작으면 귀무가설을 기각한다.
- ④ 람다는 어떤 일정 시간과 공간의 구간 안에서 발생한 평균 사건 수를 의미하지 않는다.

정답: ③ P-value가 유의수준보다 작으면 귀무가설을 기각한다.

해설: 가설검정에서 p값이 유의수준보다 작으면 귀무가설을 기각하는 것이 일반적인 규칙입니다.

71. 비교 그래프가 아닌것은?

- ① 막대그래프
- ② 레이더차트
- ③ 히트맵
- ④ 산점도

정답: ④ 산점도

해설: 산점도는 두 변수 간의 관계를 보는 상관관계 그래프이며, 비교를 위한 그래프가 아닙니다.

72. K-fold CV에 대한 설명 중 옳지 않은 것은?

- ① 검증, 훈련, 테스트 데이터로 이루어져 있다.
- ② $k=3$ 이상만 가능
- ③ k개의 균등한 서브셋
- ④ $k-1$ 개의 부분집합을 학습데이터로 사용

정답: ② $k=3$ 이상만 가능

해설: K-fold CV에서 k는 2 이상이면 가능하며, 3 이상으로 제한되지 않습니다.

73. 누적 히스토그램에 대한 설명으로 가장 알맞은 것은?

- ① 범주형과 수치형 모두의 분포를 알 수 있다.
- ② 히스토그램의 y축을 평균으로도 나타낼 수 있다.
- ③ 계급수를 잘 정해야 정확한 분포 파악이 가능하다.
- ④ 누적확률분포표는 누적확률밀도함수와 비슷한 형태를 보인다.

정답: ③ 계급수를 잘 정해야 정확한 분포 파악이 가능하다.

해설: 히스토그램에서 계급의 수와 폭은 분포의 모양에 큰 영향을 미치므로 적절한 설정이 중요합니다.

74. 과적합일 때 대응방법이 아닌 것은?

- ① Regularization
- ② Batch Normalization
- ③ Drop-out
- ④ Max Pooling

정답: ④ Max Pooling

해설: Max Pooling은 차원축소를 위한 방법이며, 과적합 해결을 직접적인 목적으로 하지 않습니다.

75. 회귀분석 $\log(\text{odds}) = a + bx$ 설명으로 가장 거리가 먼것은?

- ① a,b 둘다 0이면 y확률 0이다.
- ② Log 연산을 통해 0에서 1사이의 Logit을 획득한다.
- ③ 오즈(Odds)는 클래스 0에 속하는 확률에 대한 클래스 1에 속하는 확률의 비이다.
- ④ 승산비(Odd Ratio)사건이 발생한 확률과 발생하지 않을 확률 간의 비율이다.

정답: ① a,b 둘다 0이면 y확률 0이다.

해설: a,b가 모두 0이면 $\log(\text{odds}) = 0$, 즉 $\text{odds} = 1$ 이 되어 확률은 0.5가 됩니다.

76. 혼동행렬에서의 FN 해석에 대한 것으로 알맞은 것은?

- ① 예측값 False 실제값 False
- ② 예측값 False 실제값 True
- ③ 예측값 True 실제값 False
- ④ 예측값 True 실제값 True

정답: ② 예측값 False 실제값 True

해설: FN(False Negative)은 실제로는 Positive인데 Negative로 잘못 예측한 경우입니다.

77. 데이터 불균형이 있을 경우 사용하는 평가지표로 옳지 않은 것은?

- ① 민감도
- ② 정확도
- ③ 오분류율
- ④ ROC곡선

정답: ② 정확도

해설: 데이터 불균형이 있을 때 정확도는 편향된 결과를 보일 수 있어 적절하지 않습니다. 대신 민감도, 특이도, F1-score, ROC곡선 등을 사용합니다.

78. 보고서 작성시 방법으로 가장 거리가 먼 것은?

- ① 전문용어를 많이 사용한다.
- ② 쉽게 이해할 수 있도록 작성한다.
- ③ 비즈니스에 사용할 수 있도록 한다.
- ④ 보고서를 통해 성과 기준과 기여도를 표현할 수 있도록 한다.

정답: ① 전문용어를 많이 사용한다.

해설: 효과적인 보고서는 독자가 쉽게 이해할 수 있도록 작성해야 하며, 과도한 전문용어 사용은 피해야 합니다.

79. 회귀계수의 유의성 검정 (유사한 유형)

어느 중학교에서 1학년 학생들의 키의 차이가 2학년이 되면 더 커질 것이라고 예상된다. 1학년에 6명을 뽑고, 2학년에 8명을 뽑아서 각각의 성적의 분산을 조사해 봤더니, 1학년의 분산은 10.0이었고 2학년의 분산은 50.0이었다. 두 모집단의 분산은 같다고 볼 수 있을까? $\alpha=0.05$ 에서 검정해보자.

- ① F통계량, $p\text{-value} < \text{유의수준}$, 귀무가설 채택
- ② F통계량, $p\text{-value} < \text{유의수준}$, 귀무가설 기각
- ③ 카이제곱, $p\text{-value} < \text{유의수준}$, 귀무가설 채택
- ④ 카이제곱, $p\text{-value} < \text{유의수준}$, 귀무가설 기각

정답: ② F통계량, $p\text{-value} < \text{유의수준}$, 귀무가설 기각

해설: 두 모집단의 분산 비교는 F검정을 사용합니다. $F = 50.0/10.0 = 5.0$ 으로, 이는 상당히 큰 값이므로 귀무가설(분산이 같다)을 기각합니다.

80. 분석모형 리모델링 및 활용 과정별 명칭과 그 내용에 대하여 잘못 짝지어진 것은?

정의 → 표준화 → () → 일반화

- ① 정규화
- ② 최적화
- ③ 합리화
- ④ 중복제거

정답: ② 최적화

해설: 분석모형의 일반적인 과정은 정의 → 표준화 → 정규화 → 일반화 순서입니다. 최적화는 이 과정에서 적절하지 않습니다.

정리

이 문제집은 빅데이터분석기사 실기 시험의 4개 과목을 모두 포함하고 있습니다:

1과목: 빅데이터의 이해 (20문제)

- 빅데이터 기술, 개인정보보호, 데이터 저장 및 처리 기술

2과목: 빅데이터 탐색 (20문제)

- 통계적 분석, 데이터 전처리, 탐색적 데이터 분석

3과목: 빅데이터 모델링 (20문제)

- 머신러닝, 딥러닝, 통계 모델링 기법

4과목: 빅데이터 결과 해석 (20문제)

- 모델 평가, 시각화, 결과 해석 및 보고서 작성

각 문제에 대해 정답과 상세한 해설을 제공하여 학습에 도움이 되도록 구성했습니다. 특히 계산 문제의 경우 풀이 과정을 포함하여 이해를 돕도록 했습니다.